

算

动作  $a$  状态  $s$  奖励  $r$  状态转移概率  $P(s|s', a)$  策略概率  $\pi(a|s)$

4城市旅行商问题 城市集合为  $\{1, 2, 3, 4\}$ , 起点固定为城市 1

TSP 建模 状态  $s = (c, v)$   $c$  为当前城市,  $v$  为已访问城市集合

动作 选择一个未访问的城市

奖励函数  $r(s, a) = -d(c, a)$

折扣因子  $\gamma = 1$

学习率  $\alpha = 0.5$

距离信息  $d(2, 3) = 5$   $d(2, 4) = 2$

当前状态  $s_t = (2, \{1, 2\})$  执行动作  $A_t = 4$  得到奖励  $R_t = -2$  转移到下一状态  $s_{t+1} = (4, \{1, 2, 4\})$

Q值估计 ( $\tilde{Q}$ )  $\tilde{Q}((2, \{1, 2\}), 3) = -5$   $\tilde{Q}((2, \{1, 2\}), 4) = -10$

$\tilde{Q}((4, \{1, 2, 4\}), 3) = -11$   $\tilde{Q}((4, \{1, 2, 4\}), 1) = -7$

问题: 计算 ①  $\max_{a \in A} \tilde{Q}(s_{t+1}, a)$  ②. 目标值  $\hat{y}_t$  ③. 更新后的  $\hat{Q}(s_t, A_t)$

$$\begin{aligned} \text{①. } s_{t+1} &= (4, \{1, 2, 4\}) & \text{②. } \hat{y}_t &= r_t + \gamma \max_{a \in A} \hat{Q}(s_{t+1}, a) & \text{③. } \tilde{Q}((2, \{1, 2\}), 4) \\ \text{可选动作 } &\{1, 3\} & & & \nearrow \\ \tilde{Q}((4, \{1, 2, 4\}), 3) &= -11 & & = -2 + 1 \times (-7) & (1-\alpha)\tilde{Q}((2, \{1, 2\}), 4) + \alpha \cdot \hat{y}_t \\ \tilde{Q}((4, \{1, 2, 4\}), 1) &= -7 & & = -9 & = 0.5 \times (-10) + 0.5 \times (-9) \\ \max_{a \in A} \hat{Q}(s_{t+1}, a) &= -7 & & & = -9.5 \quad (\text{从 } -10 \text{ 更新到 } -9.5) \end{aligned}$$

如果多步, 先更新最后一步, 从后往前推