



南开大学人工智能学院
College of Artificial Intelligence

 南开大学 |

面向行业场景的 数据+知识双轮驱动的大模型应用

南开大学 人工智能学院
机器智能研究所

刘杰

- 数据 + 知识 双轮驱动
- 面向企业应用的大模型训练
- 基于大模型的知识抽取
- 大模型的知识增强算法
- 智能体及场景应用案例

人工智能的层次与分类




分析型AI (Analytical AI)

人类擅长分析事物，而机器在这方面甚至做得就更好了。机器可以分析一组数据，并在其中找到许多用例 (use case) 的模式，这被称为“分析型AI (Analytical AI)”，或传统AI。



生成式AI (Generative AI)

但是人类不仅擅长分析事物。我们也擅长创造。我们写诗，设计产品，制作游戏，编写代码。最近，机器开始尝试创造有意义和美丽的东西，这个新类别被称为“生成式AI (Generative AI)”，这意味着机器正在生成新的东西，而不是分析已经存在的东西。




语义理解：生成式模型推动认知智能快速前进

怎么样才算让“计算机”做到“理解”语义？

人脑中的语义，是什么？
计算机中的语义，是什么？

是否能够完整这种从“人脑”到“计算”的转化？

词汇及相关术语 (terms) 都激活了大脑同一个区域。比如，大脑左边，耳朵以上，这块小面积区域代表着单词「受害人 (victim)」，这块区域也对「杀害 (killed)」，「宣告有罪 (convicted)」，「谋杀 (murdered)」和「认罪 (confessed)」有反应。大脑右侧，近头部顶端，也是会对以下词汇产生反应的大脑位置之一：「妻子」、「丈夫」、「孩子」、「父母」。



GPT系列大模型



- **参数扩展：** 参数规模数量呈指数级增长
- **预训练-微调范式：** 无标签文本数据预训练、特定任务微调、任务特化学习、细粒度的控制策略
- **Transformer架构：** 高效并行计算和长距离依赖捕捉
- **自回归生成式预训练：** 生成连贯、富有逻辑的文本、连贯性生成
- **模型泛化能力：** NLP任务中展现出更强的泛化能力、跨任务适应
- **零样本/少样本学习：** 有效学习、降低数据标注成本
- **多语言支持：** 跨语言的知识迁移和应用

“提示语”：AI模型应用新范式

信息处理类

技术解析

科研场景

你是一位人工智能研究员，请根据给定的材料“AI文档”的技术原理：

1. 阐述其核心Transformer结构
2. 说明其在自然语言处理中的应用
3. 列举2个实际应用场景

输出要求：分点说明，每点不超过100字

论文总结

学术场景

作为学术文献助手，请从以下摘要中提取：

（请填入摘要文本）

输出结构：

1. 研究目的 - 一句话概括
2. 关键数据 - 表格对比实验数据/对照值
3. 结论价值 - 一句话说明

内容创作类

科幻创作

文学创作

作为科幻作家，创作关于“量子通信危机”的故事梗概：

- 故事结构：技术突破 → 意外后果 → 文明抉择
- 每章用符号开头（例：☢️技术革命）
- 包含2个角色对话片段

风格参考：《三体》的硬科幻特征

营销文案

商业应用


【产品宣传】智能手表PulseTech，主打健康监测功能

生成3条社交媒体文案：

1. 突出睡眠分析核心卖点
2. 使用网络流行语（如“卷王必备”）
3. 每条含悬念式提问

格式：标题（15字内），正文（80字内）

DeepSeek的家族模型



知识与数据的双轮驱动

第三代人工智能的发展方向:

融合【知识】和【数据】，

搭建一个双轮驱动的人工智能框架。

双轮驱动的根本任务:

- 知识抽取 —— 语言模型提取知识
- 知识增强 —— 知识图谱增强模型

Knowledge Graphs (KGs)

缺点:

- 隐含知识
- 幻觉
- 答案不确定
- 黑盒
- 缺乏领域特定/新知识

优点:

- 结构性知识
- 准确
- 答案确定
- 可解释性
- 特定领域知识扩展

优点:

- 通用知识
- 语言处理能力
- 可推广性

缺点:

- 不完整
- 缺乏语言理解能力
- 未见事实难处理

Large Language Models (LLMs)