

建模 2017.9

卡尔曼滤波(评教系统)

$$\begin{cases} x_J = 80 \\ \sigma_J^2 = 3 \end{cases} \quad \begin{cases} x_{\#} = 40 \\ \sigma_{\#}^2 = 10 \end{cases}$$

过程模型

$$\begin{cases} x(k+1) = x(k) \\ y(k+1) = x(k+1) + v(k+1) \end{cases}$$

$$\begin{cases} \hat{x}_1 = x_J \\ \hat{\sigma}_1^2 = \sigma_J^2 \end{cases} \quad \begin{cases} \hat{y} = x_J \\ \hat{\sigma}_y^2 = \sigma_J^2 \end{cases}$$

$$\hat{x}_2 = \hat{x}_1 + W(y - \hat{y}) = x_J + W(x_{\#} - x_J) = x_J + \frac{\sigma_J^2}{\sigma_J^2 + \sigma_{\#}^2} (x_{\#} - x_J) = \frac{\sigma_{\#}^2}{\sigma_J^2 + \sigma_{\#}^2} x_J + \frac{\sigma_J^2}{\sigma_J^2 + \sigma_{\#}^2} x_{\#}$$

$$\hat{\sigma}_2^2 = \sigma_J^2 - \sigma_J^2 (\sigma_J^2 + \sigma_{\#}^2)^{-1} \sigma_J^2 = \frac{\sigma_J^2 \cdot \sigma_{\#}^2}{\sigma_J^2 + \sigma_{\#}^2} < \begin{cases} \sigma_J^2 \\ \sigma_{\#}^2 \end{cases}$$

其中, $W = \sigma_J^2 (\sigma_J^2 + \sigma_{\#}^2)^{-1} = \frac{\sigma_J^2}{\sigma_J^2 + \sigma_{\#}^2}$

$$\begin{cases} \hat{x}(k+1) = \Phi(k) \hat{x}(k) + \Gamma(k) w(k) \\ y(k+1) = H(k+1) \hat{x}(k+1) + v(k+1) \end{cases}$$

$$E(w(k)) = E(v(k)) = 0; E(w(k) w^T(k)) = Q(k); E(v(k) v^T(k)) = R(k)$$

预测

$$\begin{cases} \hat{x}(k+1|k) = \Phi(k) \hat{x}(k|k) \\ P(k+1|k) = \Phi(k) P(k|k) \Phi^T(k) + \Gamma(k) Q(k) \Gamma^T(k) \end{cases}$$

更新

$$\begin{cases} \hat{x}(k+1|k+1) = \hat{x}(k+1|k) + W(k+1) [y(k+1) - \hat{y}(k+1|k)] \\ P(k+1|k+1) = P(k+1|k) - W(k+1) H(k+1) P(k+1|k) \end{cases}$$

$$W(k+1) = P(k+1) H^T(k+1) [H(k+1) P(k+1) H^T(k+1) + R(k+1)]^{-1}$$

$$P(k+1) = P(k+1|k) H^T(k+1) [H(k+1) P(k+1|k) H^T(k+1) + R(k+1)]^{-1}$$

$$W(k+1) = \arg \min P(k+1|k+1)$$

假设 平时成绩 $y_{\#}$ 是对分数的预测。平时成绩的方差 $\sigma_{\#}^2$ 是对协方差矩阵的预测。

期末... $y_{\#}$ 是对分数的真实值。期末成绩的方差 $\sigma_{\#}^2$ 是对状态估计的协方差矩阵。

解: 建立卡尔曼观测器模型

$$\begin{cases} x(k+1) = x(k) \\ y(k+1) = x(k+1) + v(k+1) \end{cases}$$

$$\begin{cases} \hat{\theta}_{N+1} = \hat{\theta}_N + \frac{P_N \varphi_{N+1}}{\varphi_{N+1}^T P_N \varphi_{N+1} + W_{N+1}^{-1}} [y(N+1) - \varphi_{N+1}^T \hat{\theta}_N] \\ P_{N+1} = P_N - \frac{P_N \varphi_{N+1} \varphi_{N+1}^T P_N}{\varphi_{N+1}^T P_N \varphi_{N+1} + W_{N+1}^{-1}} \end{cases}$$

增益向量(使误差平方和最小)
预测偏差

正规方程: $\Phi_N^T \Phi_N \theta = \Phi_N^T Y_N$

$$\begin{cases} \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} (\Phi_N^T Y_N) \\ P = \sigma^2 (\Phi_N^T \Phi_N)^{-1} \end{cases}$$

预测

$$\begin{cases} \hat{x}_1 = y_{\#} \\ \hat{\sigma}_1^2 = \sigma_{\#}^2 \end{cases} \quad \text{即} \begin{cases} \hat{x}(k+1|k) = \hat{x}(k|k) \\ P(k+1|k) = P(k|k) \end{cases} \quad \text{其中 } H=1, \phi=1$$

更新

$$\begin{cases} \hat{x} = y_{\#} + W(y_{\#} - \hat{y}_{\#}) \\ \hat{\sigma}^2 = \sigma_{\#}^2 - W \sigma_{\#}^2 \end{cases} \quad \text{即} \begin{cases} \hat{x}(k+1|k+1) = \hat{x}(k+1|k) + W(k+1) [y(k+1) - \hat{y}(k+1|k)] \\ P(k+1|k+1) = P(k+1|k) - W(k+1) \cdot P(k+1|k) \leq P(k+1|k) \end{cases}$$

$$W = \sigma_{\#}^2 (\sigma_{\#}^2 + \sigma_{\#}^2)^{-1}$$

$$\begin{cases} \hat{x} = y_{\#} + \frac{\sigma_{\#}^2}{\sigma_{\#}^2 + \sigma_{\#}^2} (y_{\#} - \hat{y}_{\#}) = \frac{\sigma_{\#}^2}{\sigma_{\#}^2 + \sigma_{\#}^2} y_{\#} + \frac{\sigma_{\#}^2}{\sigma_{\#}^2 + \sigma_{\#}^2} y_{\#} \\ \hat{\sigma}^2 = \frac{\sigma_{\#}^2 \sigma_{\#}^2}{\sigma_{\#}^2 + \sigma_{\#}^2} < \begin{cases} \sigma_{\#}^2 \\ \sigma_{\#}^2 \end{cases} \end{cases}$$

牛拉: $\theta^{(i+1)} = \theta^{(i)} - H_1^{-1} G_1$

麦考特: $\theta^{(i+1)} = \theta^{(i)} - \frac{1}{2} P_1^{-1} G_1$

$$H_1 = \frac{\partial^2 J}{\partial \theta^2} \bigg|_{\theta=\theta^{(i)}} \quad G_1 = \frac{\partial J}{\partial \theta} \bigg|_{\theta=\theta^{(i)}}$$

$$P_1 = \Sigma \frac{\partial f}{\partial \theta} \bigg|_{\theta=\theta^{(i)}} \cdot \left(\frac{\partial f}{\partial \theta} \right)^T \bigg|_{\theta=\theta^{(i)}} \quad G_1 = \frac{\partial J}{\partial \theta} \bigg|_{\theta=\theta^{(i)}} = -2 \Sigma \left(\frac{\partial f}{\partial \theta} \right) \bigg|_{\theta=\theta^{(i)}} [y(k) - f(u(k), \theta^{(i)})]$$

$y = f(u, \theta) \quad J(\theta) = \sum_{k=1}^N e^2(k)$ 将 $J(\theta)$ 在 $\theta = \theta^{(i)}$ 处二次化。

$$J(\theta) = J(\theta^{(i)}) + \left(\frac{\partial J}{\partial \theta} \right)^T \bigg|_{\theta=\theta^{(i)}} (\theta - \theta^{(i)}) + \frac{1}{2} (\theta - \theta^{(i)})^T \frac{\partial^2 J}{\partial \theta^2} \bigg|_{\theta=\theta^{(i)}} (\theta - \theta^{(i)}) + R_N$$

麦: $y = f(u, \theta)$ 将 $f(u, \theta)$ 在 $\theta = \theta^{(i)}$ 处线性化: $f(u, \theta) = f(u, \theta^{(i)}) + \left(\frac{\partial f}{\partial \theta} \right)^T \bigg|_{\theta=\theta^{(i)}} (\theta - \theta^{(i)})$

$$J(\theta) = \sum e^2(k) = \sum [y(k) - f(u(k), \theta^{(i)}) - \left(\frac{\partial f}{\partial \theta} \right)^T \bigg|_{\theta=\theta^{(i)}} (\theta - \theta^{(i)})]^2$$

一. 判断

1. 化学反应方程式是数学模型 (✓)
2. 系统辨识根据理论法而不是实验法 (X)
3. 辨识是为了辨别系统内部结构和机理 (X)
目的: ①估计参数 ②得到仿真模型 ③预测 ④控制
4. 噪声为零均值高斯白噪声时, 最小二乘和极大似然对参数的均值和方差估计均是劣估计 (X) 均值劣, 方差不劣
5. 遗忘因子法, 当系统变化由快至平稳时, 遗忘因子变大 (✓)

二. 选择

1. 渐消记忆法是在辨识过程中保持 (D) 不变。
A. 新信息 B. 数据规模 限定记忆法 C. 信息矩阵 遗忘因子法 D. 遗忘因子 渐消记忆法
2. 病态不能用以下 (C) 来判断。
A. $\|A^{-1}\| \|A\| > 1000$ B. $\det(A) \approx 0$ C. $\text{trace}(A) \approx 0$ D. $\frac{|\lambda_{\max}|}{|\lambda_{\min}|} > 100$
3. 模型的阶不能用 (A) 来辨识。
A. 牛顿-拉夫森算法 B. 损失函数 C. F 检验 D. 赤池信息准则 AIC
4. 以下不能用线性最小二乘估计的是 (A)。
A. $y = \sum e^b(k)$ B. 行列式法
5. 关于 BP 算法不正确的是 (A)。
A. BP 算法用于无监督学习 B. 当确定中心点后, 权值由迭代算法确定 C. 中心点和权值的时标往往不同 D.
7. 麦肯特方法

三. 名词解释

1. 辨识: 在输入输出数据的基础上, 从一组给定的模型中, 确定一个与所测系统近似的模型。
2. 病态方程: 矩阵 $\Phi_N^T \Phi_N$ 虽然满秩, 但其行列式的值很小, 正规方程式 $\Phi_N^T \Phi_N \theta = \Phi_N^T y_N$ 的解对数据特别灵敏, 这种情况称为“病态”, 相应地正规方程称为病态方程。
3. GMDH (数据处理的分组方法): 对复杂系统的一种启发式自组织建模方法, 借助生物控制论中的自组织原理, 用启发式的方法提出的一套建模方法。
4. 遗传算法: 以达尔文的生物进化论和孟德尔遗传变异理论为基础, 模拟自然界进化过程, 自适应、启发式、全局优化的搜索算法。

四. 大题

前向: $y(k+1) + a y(k) = b u(k) + e(k+1)$

反馈: $u(k) = c y(k)$

闭环系统是否可以辨识, 说明理由。

如不可辨识提供两个策略, 使其可辨识。

答: $\because u(k) = c y(k) \therefore -u(k) + c y(k) = 0$

$\therefore$ 对任意 λ , $\lambda(-u(k) + c y(k)) = 0$

$$J(a, b) = \sum_{k=1}^N [y(k+1) + a y(k) - b u(k)]^2$$

$$= \sum [y(k+1) + a y(k) - b u(k) + \lambda(-u(k) + c y(k))]^2$$

$$= \sum [y(k+1) + (a + \lambda c) y(k) - (b + \lambda) u(k)]^2$$

$$= J(a + \lambda c, b + \lambda)$$

使 $J(a, b)$ 达到极小的参数不惟一, 不可辨识。

方法: ① 提高反馈控制阶次。

② 多个控制器相互切换

五. 大题: 写出一次完成最小二乘与递推最小二乘的公式

及区别. $(\phi_N^T \phi_N) \theta = \phi_N^T Y_N$ 正规方程

一次完成最小二乘: $\hat{\theta} = (\phi_N^T \phi_N)^{-1} (\phi_N^T Y_N)$

$$P = \sigma^2 (\phi_N^T \phi_N)^{-1}$$

$$\begin{aligned} \text{递推最小二乘} \quad \hat{\theta}_{N+1} &= \hat{\theta}_N + \frac{P_N \phi_{N+1}}{\phi_{N+1}^T P_N \phi_{N+1} + 1} [y_{N+1} - \phi_{N+1}^T \hat{\theta}_N] \\ P_{N+1} &= P_N - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + 1} \end{aligned}$$

区别: 一次完成最小二乘是基于全部数据一次处理得到的

递推: 每取得一个新数据, 就根据新数据对原估计量进行修正, 从而得到(改善后)新估计量.

六. F 检验, 并确定模型的阶.

$$F(2, N-2n_2) = \frac{J(n_1) - J(n_2)}{J(n_2)} \cdot \frac{N-2n_2^*}{2} \quad (n_2 = n_1 + 1, N=100)$$

$\alpha = 0.05$, $F_{0.05}(2, 100) = 4.85$, 完成下表, 并确定模型的阶.

n	1	2	3	4	5	6	7
J(n)							
F				9.43	3.51	0.99	

书例 $F_{0.05}(2, 100) = 3.09$ 由 $4 \rightarrow 5$, $F = 3.51 > 3.09$, J_n 减少显著
由 $5 \rightarrow 6$, $F = 0.99 < 3.09$, J_n 减少不显著
 $\therefore n = 5$

七. BP 算法. 隐含层和输出层的输入输出关系及权值修正公式.

修正公式. 输入 $X = [x_1, \dots, x_p]^T$

输出 $Y = [y_1, \dots, y_n]^T$

隐含层输入 $I_{Hj} = \sum_k w_{jk} x_k$

输出 $O_{Hj} = f(I_{Hj})$

输出层输入 $I_{Yi} = \sum_j w_{ij} O_{Hj}$

输出 $O_{Yi} = f(I_{Yi})$

隐含 $\rightarrow$ 输出 $w_{ij}(t+1) = w_{ij}(t) - \eta \frac{\partial J}{\partial w_{ij}}$

$$\frac{\partial J}{\partial w_{ij}} = \sum [y_i(t) - O_{Yi}(t)] (-f'(I_{Yi})) O_{Hj}$$

输入 $\rightarrow$ 隐含 $w_{jk}(t+1) = w_{jk}(t) - \eta \frac{\partial J}{\partial w_{jk}}$

$$\frac{\partial J}{\partial w_{jk}} = \frac{\partial J}{\partial O_{Hj}} \cdot \frac{\partial O_{Hj}}{\partial w_{jk}}$$

$$= \sum_i \sum [y_i(t) - O_{Yi}(t)] (-f'(I_{Yi})) w_{ij} f'(I_{Hj}) x_k$$

$$J_{\text{隐}} = \frac{1}{2} \sum [y_i(t) - \hat{y}_i(t)]^T [y_i(t) - \hat{y}_i(t)] = \frac{1}{2} \sum \sum [y_i(t) - O_{Yi}(t)]^2$$

八. $AX = B$

$$A = (a_{ij})_{M \times N} \quad X = (x_1, \dots, x_N)^T \quad B = (b_1, \dots, b_M)^T$$

用遗传算法求近似解.

给出二进制编码方式及适应函数表达式

① 编码假设 $\theta = [a_1, \dots, a_n]^T$, 其中 $a_i \in [L_i, U_i]$ (值域) 精度 10^{-2}
其编码是长度为 m 的 0, 1 串: $[b_{m-1}, \dots, b_0]$ 小数点后 2 位

1. 将二进制字符串 $[b_{m-1}, \dots, b_0]$ 转换成十进制数

$$[b_{m-1}, \dots, b_0]_2 = \left(\sum_{i=0}^{m-1} b_i \cdot 2^i \right)_{10} = a_i'$$

2. 得到相应实数: $a_i = L_i + \frac{(U_i - L_i)}{2^{m-1}} a_i'$

$$m_i \text{ 满足: } 2^{m_i-1} \leq (U_i - L_i) \times 10^2 < 2^{m_i}$$

$$m = \max_i m_i \text{ 用 } m \text{ 位 } 0-1 \text{ 串表示 } \theta.$$

② 种群初始化

$$\text{定义代价函数 } J(X) = (AX - b)^T (AX - b)$$

随机初始化 N 个 m 位 0-1 串.

J 越小, X 越准确

③ 适应度函数 $f(\theta) = \frac{1}{1+J(\theta)}$

因此定义适应度函数

$$F = \frac{1}{1+J(X)}$$

④ 选择 ⑤ 交叉 ⑥ 变异

⑦ 终止.

⑧ 编码

P_{224} 设待求参数构成一个 n 维向量 θ , $n=38$.

用二进制编码, 要求精度为小数点后 4 位, 每个变量

值域为 $[-100, 100]$, $\therefore 2^{20} < 200 \times 10^4 \leq 2^{21}$

每一个变量要用 21 位 0, 1 串表示.

一个染色体长度 $m = 38 \times 21 = 798$, 每 21 位对应一个实数 θ_i 的值.

⑨ 评价函数取为 $f(\theta) = \frac{100}{1+J(\theta)}$ (100 起放大作用).

⑩ 遗传操作: 单点交叉, 两点交叉和变异.

九. $y = e^{at}$ 牛顿-拉夫森算法, 率律 α .

已知第 $i-1$ 次率律参数为 θ_{i-1} , 试求第 i 次率律的参数 θ_i

$$\text{答: } \theta_i = \frac{\partial J}{\partial \theta} \bigg|_{\theta=\theta_{i-1}} = \frac{J = \sum_k (y(k) - e^{at})^2}{\partial \theta}$$

$$G_{i-1} = \frac{\partial J}{\partial \theta} \bigg|_{\theta=\theta_{i-1}} = \left[2 \sum_k [y(k) - e^{at}] \cdot (-te^{at}) \right] = -2te^{at} \sum_k [y(k) - e^{at}]$$

$$H_{i-1} = \frac{\partial^2 J}{\partial \theta^2} = -2t^2 e^{at} \sum_k [y(k) - e^{at}]$$

$$\theta_i^{(1)} = \theta_{i-1}^{(1)} - \rho H_{i-1}^{-1} G_{i-1}$$

1. 一元高斯分布

高斯分布使得只需要两个参数就能确定一个连续的概率分布。

均值和方差, 使得高斯分布易于计算和推断。

2个高斯分布的积还是高斯分布。

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \sigma \text{ 越大, 越扁}$$

2. 求解一元高斯分布: 最大似然估计

似然: 给定模型参数, 观测值出现的概率。

$$p(\{x_i\} | \mu, \sigma) \leftarrow \text{likelihood}$$

问题即: 给定观测值 $\{x_i\}$, 求 μ 和 σ , 使得似然函数最大: $\hat{\mu}, \hat{\sigma} = \arg \max_{\mu, \sigma} p(\{x_i\} | \mu, \sigma)$

$$p(\{x_i\} | \mu, \sigma) = \prod_{i=1}^N p(x_i | \mu, \sigma) \quad \text{观测值 } \{x_i\} \text{ 相互独立}$$

$$\text{目标} \Rightarrow \hat{\mu}, \hat{\sigma} = \arg \max_{\mu, \sigma} \prod_{i=1}^N p(x_i | \mu, \sigma) = \arg \max_{\mu, \sigma} \ln \left\{ \prod_{i=1}^N p(x_i | \mu, \sigma) \right\}$$

$$= \arg \max_{\mu, \sigma} \sum_{i=1}^N \ln p(x_i | \mu, \sigma)$$

$$\ln p(x_i | \mu, \sigma) = \ln \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right)$$

$$= -\frac{(x_i - \mu)^2}{2\sigma^2} - \ln \sigma - \ln \sqrt{2\pi}$$

$$= \arg \max_{\mu, \sigma} \sum_{i=1}^N \left(-\frac{(x_i - \mu)^2}{2\sigma^2} - \ln \sigma \right)$$

$$= \arg \min_{\mu, \sigma} \sum_{i=1}^N \left(\frac{(x_i - \mu)^2}{2\sigma^2} + \ln \sigma \right)$$

$$\text{令 } J(\mu, \sigma) = \sum_{i=1}^N \left(\frac{(x_i - \mu)^2}{2\sigma^2} + \ln \sigma \right)$$

$$\text{目标: 使得 } J(\mu, \sigma) \text{ 最小. 求偏导 } \frac{\partial J}{\partial \mu} = \sum_{i=1}^N \frac{-2(x_i - \mu)}{2\sigma^2} = \frac{1}{\sigma^2} (N\mu - \sum_{i=1}^N x_i) = 0$$

$$\text{解得 } \hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

将 $\mu = \hat{\mu}$ 带入函数 $J(\mu, \sigma)$ 得到函数 $J'(\sigma)$, 其取最小值时关于 σ 的导数 = 0:

$$\frac{dJ'(\sigma)}{d\sigma} = \frac{N}{\sigma} - \sum_{i=1}^N \frac{(x_i - \hat{\mu})^2}{\sigma^3} = \frac{1}{\sigma} \left(N - \frac{1}{\sigma^2} \sum_{i=1}^N (x_i - \hat{\mu})^2 \right) = 0 \quad \text{解得 } \hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})^2$$

$$\text{总结答案为: } \hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})^2$$

3. 多元高斯分布

$$p(\vec{x}) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu}) \right\} \quad D: \text{维数}, \Sigma: \text{协方差矩阵}$$

$$\Sigma = \begin{bmatrix} \sigma_{x_1}^2 & \sigma_{x_1} \sigma_{x_2} \\ \sigma_{x_2} \sigma_{x_1} & \sigma_{x_2}^2 \end{bmatrix}$$

$\sigma_{x_1}^2, \sigma_{x_2}^2$ 分别表示变量 x_1, x_2 的独立方差。

$\sigma_{x_1} \sigma_{x_2}$ 表示两个变量之间的相关性。