

2120190304

建模与系统辨识

Date. / /

闭卷考试，版书为主，教材为辅，平时 30% + 考试 70%

最小二乘，梯度下降会考的难一点，其他的都是讲什么考什么。

1月11日下午考试

考试范围：① 单选：8个 × 3分

② 名词解释：3个 × 4分 = 12分

③~⑨：大题，会有问答题，计算题，没有证明题。

第一章：有选择，名词解释，没有专门针对第一章的大题

化学式

之前出过，今年不能： $2H_2 + O_2 \rightarrow 2H_2O$ / $H_2O \rightarrow H_2 + O_2$ 是数学模型 ✓

第二章：最小二乘必考，最小二乘的正规方程

最小二乘的性质：一致性，无偏性

病态方程求解：Householder 变换，主成分估计，不会指定具体方法。

极大似然估计： $(\frac{1}{\sqrt{2\pi}})^N e^{-\frac{1}{2} \sum_{i=1}^N \frac{(y_i - \hat{y}_i)^2}{\sigma^2}}$... / $\frac{1}{\sqrt{\det \Sigma}}$... 不用背

第三章：最小二乘 最重要的是推导最小二乘，要自己会推

时变系统的辨识：变阶，记忆，变遗忘因子等等。

第四章：辅助变量法，闭环系统的辨识

第五章：四个考一个，不出损失函数 → 三个考一个，不考推导。

第八章：8.3、8.4、8.5 必考（牛拉，麦奎特，迭代三个考一个）

GMDH 不考计算，不排除考问答题。课上总结的 GMDH 的优点缺点好好看。

神经网络及下一章，讲什么考什么。

▲ 试题中间有两三个大题，要灵活处理。

▲ 卡尔曼滤波必考，公式是否背取决于自己。

如： $\bar{x} = w_1 x_1 + w_2 x_2$

$\sim N(x_1, \sigma_1^2)$

$\downarrow$
 σ_1^2

$\downarrow$
 σ_2^2

→ 归一化处理

$\sim N(x_2, \sigma_2^2)$

0201907

9月29日 第一次课

第一章 绪论

1.1 引言

1. 系统: 按某种相互依赖关系联系在一起^②的具有一定规律^①的一些客体的集合。

① 控制系统: 过程控制系统 (四大基本量: 温度、压力、流量(流速)、液位)

运动控制系统: 以电机控制


智能控制系统: 以无人机、机器人、自主飞行器为对象。

(智能: 对工作环境具有适应、学习, 甚至交互的能力。)

② 社会经济系统(有人): 人口、GDP、价格、商品价格

房价: ...

③ 生物系统: 人、人体的某个器官, 如大脑...



④ 网络系统: 计算机网络、交通网络、Graph-based model (图模型)

社交网络 (social network)、multi-layer network、multiplex

多智能体 multi-agent

传感网络: sensor network

同构: 网络中的结点都相同

异构: 网络中的结点不同

⑤ 复合系统: 石化

2. 建模: 建立系统的数学模型, 用来描述系统变化的规律。(化学方程式是数学模型)


物理模型

化学模型

计算机仿真模型

数据-通用: 通过数据得到一个通用的模型

统计模型



$$M^* = \arg \min \int_0^T \|e(t)\| dt, M \in \mathcal{M}$$

Date. 2

3. 辨识 Identification recognizing

→ 建模的一种手段, 与识别没有关系。

1. A. Ziden 教授给辨识下的定义:

在输入/输出数据的基础上, 从一组给定的模型中, 确定一个与所测系统等价的模型。

special cause

$$\text{Plant: } \begin{cases} \dot{x} = f(u, x) = Ax + Bu \\ y = h(u, x) = Cx + Du \end{cases}$$

$$\text{Model } \begin{cases} x = y(t) & \text{high-order Polynomial} & \text{Pseudo-spectral} \\ u = u(t) & \text{高阶多项式} & \text{伪谱法} \\ y = \hat{y}(t) \end{cases}$$

$$\begin{cases} x = y(u, T) \\ y = \hat{y}(u, T) \end{cases} \quad T \in [0, T]$$

1.2 系统辨识

1. 辨识的目的:

① 估计某些具有特定物理意义的参数, 为系统的分析和评价提供依据。

② 得到仿真模型。

半实物仿真: 贵的部分用仿真完成, 低成本部分用实物实验完成。

建立仿真模型的原因: ① 实验费用可能太昂贵

② 系统可能是不稳定的, 实验将破坏系统的平衡, 可能会造成危险。

③ 系统的时间常数很大, 使实验进行的很慢, 以至于效果不明显。

④ 很多实验现象是不可再现的, 如自然科学、生命科学等的研究, 但仿真可再现。

⑤ 可共享。

⑥ 预测: 为了更好地控制, 为决策提供信息

⑦ 控制

cell 能力

④ 控制

不严格依赖于模型的控制器：PID、模糊控制、自适应控制、鲁棒控制

自适应控制：存在未知定常系数的情况下

线性系统：满足叠加原理

线性系统：用好的辨识方法建立一个好的模型，B值越准确，控制效果越好。

非线性系统：B值可能不准

控制：控制理论：Control Theory

控制论：Cybernetics


控制理论发展的过程：

经典控制论（维纳1948年提出），核心：反馈

需求驱动：二战瞄准需要

现代控制论（卡尔曼50年代末60年代初提出）

需求驱动：卫星 多变量状态空间形式 核心：最优



2017年10月12日 第二次课

1. 经典控制论 → 现代控制论 → 先进控制 → 智能控制 → 数据驱动控制

classical ~ Modern ~ Advanced ~ Intelligent ~ Data-driven ~

常见的先进控制：

• 自适应控制 (Adaptive Control)

• 预测控制 (Predictive Control)

• 滑模控制 (Sliding Mode Control) 非线性系统 X

• 模糊控制 (Fuzzy Control)

• 鲁棒控制 (Robust Control) 实时性差

• 学习控制 (Learning Control)

• 随机控制

• 最优控制 (Optimal Control) 实时性差 (鲁棒控制是最优控制的一种)

比较有代表性的智能控制：神经网络 NN-based

F

GA

与数据驱动相关的控制：并行控制

工业中，飞行器中用的最多的控制器：PID控制器（工业中占90%~95%）

此外，在工业中应用最成功的：自适应控制、预测控制、模糊控制

辨识的目的: ①控制

④预测 无论是为了控制的预测, 还是面向决策的预测, 都是基于模型的。

1.2.2 先验信息

关于辨识的先验信息: ①关于数据

②关于模型结构 获取模型结构方式 { 理论法

③关于参数的 测试法

1.2.3 常用的辨识算法

线性系统采用: 最小二乘、极大似然。

非线性系统采用: 最小二乘、启发式、神经网络

1.3 数学模型

1. 分类: 线性/非线性; 连续/离散; 时变/时不变; 时域/频域

状态空间/输入输出模型、确定/不确定(随机系统、鲁棒系统、模糊系统)

2. 线性系统的数学模型

①传递函数模型 描述系统的能控、能观部分

$$G(s) = C(sI - A)^{-1}B$$

②状态空间模型 $\begin{cases} \dot{x} = Ax + Bu \\ y = Cx + Du \end{cases}$


非线性系统: $\begin{cases} \dot{x} = f(x, u, t) & \text{非自治系统(难控制)} \\ y = h(x, u, t) \end{cases}$ $\dot{x} = f(x, u)$ 自治系统

③输入输出模型

$$y(k) = \sum a_i y(k-i) + \sum b_i u(k-i)$$

$$y(k) = \sum a_i u_i(k)$$

④多项式模型 $S = \frac{d}{dt}$ 一 时域的微分算子



3. 模型举例

①生物系统 ②房屋模型 ③经济系统, 如房价预测(北京、上海、深圳、杭州、厦门、南京)


④过控系统, 如锅炉的液位控制。(过控系统是房屋模型的特例)



$$\dot{x}_i = f_{i1} + f_{oi} - f_{ij} - f_{io}$$

$$f_{ij} = k_{ij} \cdot x_i \quad \text{— 线性}$$

$$f_{ij} = f(x_i) \quad \text{— 非线性}$$



$$f(x) = f(x_0) + f'(x_0)(x-x_0) + \frac{1}{2}f''(x_0)(x-x_0)^2 + \dots$$

$$F_1 = K_1 u$$

$$F_0 = K_2 \sqrt{H}$$

该系统为非线性系统, 可以在平衡点处进行线性化。

$$S \frac{dH}{dt} = F_1 - F_0$$

$$\sqrt{H} = \sqrt{H_s} + \frac{1}{2\sqrt{H_s}}(H - H_s)$$

$$S \cdot \dot{H} = K_1 u - K_2 \sqrt{H}$$

$$S \dot{H} = K_1 u - K_2 \sqrt{H_s} - \frac{K_2}{2\sqrt{H_s}}(H - H_s)$$

objective Find u , such that $H \xrightarrow{t \rightarrow \infty} H_s$


$$u = Kx$$

$$x = H - H_s$$

2017年10月19日

非线性系统转换为线性系统的方法: ^{Taylor}精确

⑤ 运动控制: 例: 移动机器人



$$q = [x, y, \theta]^T \in \mathbb{R}^{2 \times 3}$$

$$u = [u_1, u_2]^T \in \mathbb{R}^2$$

$$u_1 = \frac{v_1 + v_2}{2}$$

$$u_2 = \frac{v_1 - v_2}{b}$$

$$\begin{cases} \dot{x} = u_1 \cos \theta \\ \dot{y} = u_1 \sin \theta \\ \dot{\theta} = u_2 \end{cases}$$

$$q = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix}$$

$$\dot{q} = \begin{bmatrix} \dot{x} \\ \dot{y} \\ \dot{\theta} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} u_1 + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} u_2$$

非线性系统

此系统叫欠驱动系统: underactuated (因为输入是二维的, 输出是三维的)

非完整, 非线性, 欠驱动 nonholonomic

$$x \sin \theta - y \cos \theta = 0 \quad \text{不可解}$$

假设平衡点为 $q = (0, 0, 0)^T$

并非所有的非线性系统经泰勒公式线性化后就可以直接用。

(Stabilization 镇定(只注重结果))

Motion Control
 (移动平台的控制)
 trajectory tracking 跟踪: $T_{\text{tar}} = \int u^T R u + e^T Q e$
 path tracking / following 路径跟踪
 (路径: 几何层面, 与时间无关, 与轨迹)

planning
 path planning
 trajectory planning
 motion planning

navigation
 perception 环境感知
 sensor information processing 传感信息处理
 obstacle detection / avoidance 障碍物检测/避障
 localization
 mapping

第三章 线性静态模型的辨识

2.1 引言

1. 线性: 输入与输出之间的一种关系

如何判断一个系统是否为线性的?

① 先用非线性模型去拟合, 计算误差。

② 先用非线性高斯去拟合, 若高斯项前系数接近0, 则是线性的。

③ 先用时域的方程进行傅里叶变化后进行相位随机化, 然后再用傅里叶反变换回到时域, 看是否是线性的。若是, 则是线性的; 否则不是线性的。

2. 静态: 当前时刻系统的输出只依赖于当前时刻系统的输入, 下一时刻的输出只依赖于当前时刻系统的输出。

$$y(k) = a_0 + a_1 u(k) + a_2 u(k) + \dots + a_n u(k)$$

$$y(k) = a_1 y(k-1) + a_2 y(k-2) + \dots + 1 b u(k)$$

依赖于下一时刻的输入(状态); 本边只与本边有关.

动态: 当前时刻系统的输出不仅依赖于当前时刻系统的输入, 还与历史时刻的输入有关.

3. 一般形式

$$y(k) = a_0 + a_1 u_1(k) + \dots + a_n u_n(k)$$

$$\{u_i(k), y(k) \quad i=1, 2, \dots, n; \quad k=1, 2, \dots, N\}$$

$\{a_i\}$ 未知参数

4. 真实系统

$$y(k) = a_0 + a_1 u_1(k) + \dots + a_n u_n(k) + e(k)$$

加性噪声, 普遍存在

$$e(k) \sim N(0, \sigma^2)$$

Gaussian white noise 高斯白噪声

白噪声: 各种噪声在频谱特性上的相加, 它具有独立性(即任一时刻的采样值与其它时刻无关).

§2.2 最小二乘估计 (Least Square Estimate)

1. 问题描述

$$J(a_0, a_1, \dots, a_n) \triangleq \sum_{k=1}^N e^2(k) = \sum_{k=1}^N [y(k) - (a_0 + a_1 u_1(k) + \dots + a_n u_n(k))]^2$$

系统输出, 真实输出

模型输出

$$(\hat{a}_0^*, \hat{a}_1^*, \dots, \hat{a}_n^*) = \underset{a_i}{\operatorname{argmin}} J(a_0, a_1, \dots, a_n)$$

2. 最小二乘解

$$y(k) = a_0 + a_1 u_1(k) + \dots + a_n u_n(k) + e(k)$$

$$\text{令 } \theta = [a_0, a_1, \dots, a_n]^T, \quad \phi_k = [1, u_1(k), \dots, u_n(k)]^T$$

$$\text{则 } y(k) = \phi_k^T \theta + e(k)$$

$$\text{再令 } \Phi_N = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix} = \begin{bmatrix} 1 & u_1(1) & \dots & u_n(1) \\ 1 & u_1(2) & \dots & u_n(2) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & u_1(N) & \dots & u_n(N) \end{bmatrix} \quad N > n$$

均值: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\text{方差: } \sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$Y_N = [y(1), y(2), \dots, y(N)]^T$$

$$e_N = [e(1), e(2), \dots, e(N)]^T$$

$$\text{则 } Y_N = \Phi_N \theta + e_N$$

$$\text{目标函数: } J(\theta) = \sum_{k=1}^N e^2(k) = e_N^T e_N = (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

$$\text{令 } \frac{\partial J}{\partial \theta} = 0$$

$$\text{即令 } \frac{\partial J}{\partial \theta} = -2 \Phi_N^T (Y_N - \Phi_N \theta) = 0$$

$$\Rightarrow \Phi_N^T \Phi_N \theta = \Phi_N^T Y_N \quad \text{正规方程}$$

$$\theta \text{ 的估计值 } \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

3. 最小二乘解的性质

$$\textcircled{1} \tilde{\theta} = \hat{\theta} - \theta = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N - \theta$$

$\tilde{\theta}$: 表示误差

$$= (\Phi_N^T \Phi_N)^{-1} \Phi_N^T (\Phi_N \theta + e_N) - \theta$$

$$= (\Phi_N^T \Phi_N)^{-1} \Phi_N^T e_N \quad \tilde{\theta} \text{ 与 } e_N \text{ 估计残差或线性函数}$$

$$\textcircled{2} E(\tilde{\theta}) = E(\hat{\theta}) - E(\theta) = E(\hat{\theta}) - \theta = 0$$

$E(\tilde{\theta})$: 对 $\tilde{\theta}$ 取均值

$$\text{又 } E(\tilde{\theta}) = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T E(e_N) = 0$$

$\hat{\theta}$ 是 θ 的无偏估计

是零向量

$$e(k) \sim N(0, \sigma^2)$$

$$\Rightarrow E(\hat{\theta}) = \theta$$

$\hat{\theta}$ 是 θ 的方差最小的线性无偏估计

$$E(\hat{\theta}) \hat{\theta} = 0?$$

$\Phi_N^T \Phi_N$ 是对称正定阵

③ $\hat{\theta}$ 的方差矩阵

$$P = E[(\hat{\theta} - \theta)(\hat{\theta} - \theta)^T] = E(\tilde{\theta} \tilde{\theta}^T) = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T E(e_N e_N^T) \Phi_N (\Phi_N^T \Phi_N)^{-1} = \sigma^2 (\Phi_N^T \Phi_N)^{-1}$$

$\sigma^2 I$

$$e_N e_N^T = \begin{bmatrix} e^2(1) & e(1)e(2) & \dots & e(1)e(n) \\ e(2)e(1) & e^2(2) & \dots & e(2)e(n) \\ \vdots & \vdots & \ddots & \vdots \\ e(n)e(1) & e(n)e(2) & \dots & e^2(n) \end{bmatrix}$$

$$\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T e_N$$

$$= \left(\sum_{k=1}^N \phi_k \phi_k^T \right)^{-1} \left(\sum_{k=1}^N \phi_k e(k) \right)$$

$$\begin{aligned} \hat{\theta} &= (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N \\ &= (\Phi_N^T \Phi_N)^{-1} \Phi_N^T (\Phi_N \theta + e_N) \\ &= \theta + (\Phi_N^T \Phi_N)^{-1} \Phi_N^T e_N \\ &= \theta + \left(\sum_{k=1}^N \phi_k \phi_k^T \right)^{-1} \left(\sum_{k=1}^N \phi_k e(k) \right) \\ &= \theta + \left(\frac{1}{N} \sum_{k=1}^N \phi_k \phi_k^T \right)^{-1} \left(\frac{1}{N} \sum_{k=1}^N \phi_k e(k) \right) \end{aligned}$$

$\downarrow$
 $E(\phi_k, \phi_k^T)$

$\downarrow$
 $E(\phi_k, e(k))$

④ 估计误差

$$\begin{aligned} p &\triangleq E[(\hat{\theta} - \theta)^T (\hat{\theta} - \theta)] \\ &= E(\hat{\theta}^T \theta) \\ &= E(\text{trace}(\hat{\theta}, \hat{\theta}^T)) \\ &= \text{trace} E(\hat{\theta} \hat{\theta}^T) \\ &= \text{trace} [\sigma^2 (\Phi_N^T \Phi_N)^{-1}] \\ &= \text{trace} [\sigma^2 (\Phi_N^T \Phi_N)^{-1} P P^T] \\ &= \sigma^2 \text{trace} [P^T (\Phi_N^T \Phi_N)^{-1} P] \\ &= \sigma^2 \text{trace} [P^T (\Phi_N^T \Phi_N) P]^{-1} \\ &= \sigma^2 \text{trace} (\text{diag} \{ \lambda_1^{-1}, \dots, \lambda_n^{-1} \}) \\ &= \sigma^2 \sum_{i=1}^n \frac{1}{\lambda_i} \end{aligned}$$

(其中 $\lambda_1, \dots, \lambda_n$ 为 $\Phi_N^T \Phi_N$ 的特征根)

正矩阵是一种实对称矩阵, 正定矩阵的行列式恒为正。

定义: 设 M 是 n 阶方阵, 若对任何非零向量 x 有 $x^T M x > 0$, 则称 M 为正定矩阵。

• $\hat{\theta}^T \hat{\theta}$ 是一个数, 标量

$$\therefore \hat{\theta}^T \hat{\theta} = \text{trace}(\hat{\theta} \hat{\theta}^T)$$

• 矩阵的行列式是特征根之积;

矩阵的迹是特征根之和。

• $\Phi_N^T \Phi_N$ 是对称正定阵, 故存在正交阵 P

($P P^T = P^T P = I$), 使得

$$P^T (\Phi_N^T \Phi_N) P = \text{diag} \{ \lambda_1, \dots, \lambda_n \}$$

• $\text{tr}(AB) = \text{tr}(BA)$

$$\therefore \text{trace} [(\Phi_N^T \Phi_N)^{-1} P P^T] = \text{trace} [P^T (\Phi_N^T \Phi_N)^{-1} P]$$

$\begin{matrix} A & B \end{matrix}$
 $\begin{matrix} B & A \end{matrix}$

• 对任意矩阵: $(A^T)^{-1} = (A^{-1})^T$ $(A^{-1})^{-1} = A$

$$(AB)^T = B^T A^T \quad (AB)^{-1} = B^{-1} A^{-1}$$

• 若 A 为 n 阶实对称矩阵, 则必存在正交矩阵 Q ,

使得 $Q^T A Q = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, 其中 $\lambda_1, \dots, \lambda_n$

为 A 的特征值, 而正交矩阵 Q 的 n 个列分别是和

$\lambda_1, \dots, \lambda_n$ 对应的两两正交的单位特征向量。

Date.

$$\textcircled{5} \tilde{y} = \hat{y} - y \quad \alpha \in (0,1)$$

$$\hat{y} = \Phi_N^T \hat{\theta} \quad \hat{y}(k) = \Phi_k^T \hat{\theta}$$

$$\textcircled{6} E(\hat{y}) = y$$

$$\textcircled{7} \hat{\sigma}^2 = \frac{1}{N-n} J(\hat{\theta})$$

$$= \frac{1}{N-n} \sum_{k=1}^N [y(k) - (\hat{a}_0 + \hat{a}_1 u_1(k) + \dots + \hat{a}_n u_n(k))]^2$$

$$E(\hat{\sigma}^2) = \sigma^2$$

对于 x_i ($i=1, 2, \dots, n$)

$$\text{则 } \hat{x}_i = \frac{1}{n} \sum_{j=1}^n x_j$$

$$\sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x})^2$$

§ 2.3 病态方程及其求解

1. 病态方程

$$\text{正规方程: } \Phi_N^T \Phi_N \theta = \Phi_N^T Y_N$$

例 2.1: 设 $Ax=b$, $A = \begin{bmatrix} 99 & 99 \\ 99 & 100 \end{bmatrix}$, $b = \begin{bmatrix} 197 \\ 199 \end{bmatrix}$ 则 $x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

若 b 扰动 $\rightarrow b' = \begin{bmatrix} 197.0197 \\ 199 \end{bmatrix} \Rightarrow x' = \begin{bmatrix} -0.9700 \\ 2.9503 \end{bmatrix}$

$b'' = \begin{bmatrix} 197 \\ 199.0199 \end{bmatrix} \Rightarrow x'' = \begin{bmatrix} 2.9701 \\ -0.9502 \end{bmatrix}$

例 2.2 若 $A = \begin{bmatrix} 1 & 1 \\ 1 & 1.0001 \end{bmatrix}$, $b = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \Rightarrow x = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$

若 b 扰动 $\rightarrow b' = \begin{bmatrix} 2 \\ 2.0001 \end{bmatrix} \Rightarrow x' = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

总结: 对于 $Ax=b$, A 的行列式近似为 0, 当 b 受到扰动, 发生微小变化时, 导致解 x 发生巨大变化, 称为病态。

2. 病态的成因


$$Ax=b \quad a, b \in \mathbb{R}$$

$$\text{当 } a \rightarrow 0 \text{ 时, } x = \frac{b}{a} \quad \frac{a^2}{a} \rightarrow +\infty > M^+$$

$$\text{对于 } A = \begin{bmatrix} a_1 & 0 \\ 0 & a_2 \end{bmatrix} \quad x \in \mathbb{R}^2, b \in \mathbb{R}^2$$

$$Ax=b \quad \hat{x} = A^{-1}b \quad a_1, a_2 > 0$$

$$\text{当 } a_2 \rightarrow 0 \quad \frac{1}{a_1} \quad \frac{1}{a_2}$$



2017年10月26日

Date: / /

§ 2.3 病态方程

1. 成因: $Ax=b \quad x = \frac{1}{A}b$ 方差 $\propto \frac{1}{A}$ 方差刻画高斯分布的稳定性

2. 评价病态的程度

$$\text{对于方程 } Ax=b \quad x = A^{-1}b$$

$$\|x\| = \|A^{-1}b\| \leq \|A^{-1}\| \|b\|$$

假设 b 存在扰动 δb , 即 $b' = b + \delta b$ 则导致方程的解产生误差 δx , 即 $x' = x + \delta x$

$$\text{则 } x' = A^{-1}b' \Leftrightarrow x + \delta x = A^{-1}(b + \delta b) \Leftrightarrow \delta x = A^{-1}\delta b$$

$$\Rightarrow \|\delta x\| = \|A^{-1}\delta b\| \leq \|A^{-1}\| \|\delta b\| \quad -①$$

$$Ax=b \Rightarrow \|Ax\| = \|b\| \Rightarrow \|A\| \cdot \|x\| \geq \|b\|$$

$$\Leftrightarrow \|x\|^{-1} \leq \|A\| \|b\|^{-1}$$

$$\text{即 } \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|} \quad -②$$

$$\text{①②} \Rightarrow \frac{\|\delta x\|}{\|x\|} \leq \frac{\|A\| \cdot \|A^{-1}\|}{\|A\| \cdot \|A^{-1}\|} \cdot \frac{\|\delta b\|}{\|b\|}$$

补充: 向量范数 $\text{norm } \|\cdot\|$

$$\forall x = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n \quad \|x\|_p = (\sum |x_i|^p)^{\frac{1}{p}}$$

$$\|x\|_\infty = \max_i \{|x_i|\}$$

矩阵范数: $A = [a_{ij}]_{ij}$

$$\|A\|_1 = \max_j \{\sum_i |a_{ij}|\} \quad \|A\|_\infty = \max_i \{\sum_j |a_{ij}|\}$$

 $\|A\|_2$: $A^T A$ 的特征根的最大值开平方根

$$\|A\|_F = \sqrt{\sum_i \sum_j a_{ij}^2}$$

定义条件数 Conditional Number

$$CN = \|A\| \cdot \|A^{-1}\| \quad CN_{\infty} = \|A\|_{\infty} \cdot \|A^{-1}\|_{\infty}$$

$$CN_2 = \|A\|_2 \cdot \|A^{-1}\|_2$$

$$CN_2 = \frac{\lambda_{\max}}{\lambda_{\min}} \rightarrow \text{特征根的最大值}$$

说明: 当 $\lambda_{\max}$ 与 $\lambda_{\min}$ 很接近, 近似在一个球面上时, 说明这个系统很稳定, 因为无论沿哪个方向的误差都差不多大。

经验上说, $CN(A) \leq 100$ ✓ $x = A^{-1}b$ 方程的解认为还可以。

$$100 < CN(A) \leq 1000 \quad x = A^{-1}b \quad \times \quad \text{要小心, 此时求出的解可能不对。}$$

$$CN(A) > 1000 \quad x = A^{-1}b \quad \times \quad \text{一定不要用这个方法求解。}$$

3. 病态方程求解

$$CN = \frac{\lambda_{\max}}{\lambda_{\min}} \quad \|A\| \|A^{-1}\| > 1000 \quad \det|A| \approx 0$$

① Householder 变换法

考虑: 求解最小二乘的正规方程 $\Phi_N^T \Phi_N \theta = \Phi_N^T Y_N$

$$\theta = (\Phi_N^T \Phi_N)^{-1} (\Phi_N^T Y_N) \quad -①$$

$$J(\theta) = \sum_{k=1}^N e^2(k) = (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

$$\Phi_N \theta = Y_N \quad \Phi_N \in R^{N \times n}$$

$$\exists \text{ 正交阵 } P, P P^T = I, \text{ 使得 } P \Phi_N = \begin{bmatrix} \bar{\Phi} \\ 0 \end{bmatrix} \quad \bar{\Phi} \in R^{n \times n}$$

$$P Y_N = \begin{bmatrix} \bar{Y}_1 \\ \bar{Y}_2 \end{bmatrix}$$

$$\therefore \begin{bmatrix} \bar{\Phi} \\ 0 \end{bmatrix} \theta = \begin{bmatrix} \bar{Y}_1 \\ \bar{Y}_2 \end{bmatrix}$$

$$\Rightarrow \bar{\Phi} \cdot \theta = \bar{Y}_1$$

$$\theta = \bar{\Phi}^{-1} \cdot \bar{Y}_1 \quad \text{此处实质上与①一样, 但①的病态更严重。}$$

(因为①相当于把 Φ_N 平方后求逆了)

$$J(\theta) = (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

$$= (Y_N - \Phi_N \theta)^T P^T P (Y_N - \Phi_N \theta)$$

$$= (P Y_N - P \Phi_N \theta)^T (P Y_N - P \Phi_N \theta)$$

$$= \begin{bmatrix} \bar{Y}_1 - \bar{\Phi} \cdot \theta \\ \bar{Y}_2 \end{bmatrix}^T \begin{bmatrix} \bar{Y}_1 - \bar{\Phi} \cdot \theta \\ \bar{Y}_2 \end{bmatrix}$$

$$= (\bar{Y}_1 - \bar{\Phi} \theta)^T (\bar{Y}_1 - \bar{\Phi} \theta) + \bar{Y}_2^T \bar{Y}_2$$

最小二乘估计应使 $J(\theta)$ 达到最小。由于第二项 (等号右端) 与 θ 无关, 所以只要

$$\bar{\Phi} \theta = \bar{Y}_1 \quad ②$$

即求出参数估计 $\hat{\theta}$ 。这样, 求解最小二乘估计, 即求解正规方程的问题化为解方程组②的问题了, 而方程组②不会加重方程病态。

现在问题是如何得到满足此转换的正交变换矩阵 P 呢?



定义 (Householder 变换矩阵) $H = I - 2SS^T$, 其中 $\|S\|_2 = 1$

该矩阵的性质: 引理 2.1 ① $H^T = H$ (是对称矩阵)

$$② H^T H = I \quad (\text{是对称正交阵})$$

$$H^T \cdot H = (I - 2SS^T)(I - 2SS^T)$$

$$= I - 4SS^T + 4SS^TSS^T$$

$$= I$$

引理 2.2 Householder 变换阵之积是正交的, 即

$$P = H_n \cdot H_{n-1} \cdots H_1, \text{ 其中 } P^T P = I$$

$$\text{证明: } P^T P = H_1^T \cdots H_{n-1}^T H_n^T H_n H_{n-1} \cdots H_1$$

$$= I$$

引理 2.3 给定任意列向量 x , $\exists$ Householder 变换 $H = I - 2SS^T$, 使得

$$H \cdot x = \begin{bmatrix} \lambda \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\text{其中 } S_1 = \sqrt{\frac{1}{2}(1 - \frac{x_1}{\lambda})}, \quad S_i = -\frac{x_i}{2S_1\lambda} \quad (i=2 \dots n)$$

$$\lambda = \sqrt{x^T x} \quad S = [S_1, S_2, \dots, S_n]^T \text{ 是单位向量}$$

$$\text{证: } \|S\|_2 = S^T S = \sum S_i^2 = \dots = 1$$

$$x = H^T H x = H \cdot H x = H \cdot \begin{bmatrix} \lambda \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$H = I - 2SS^T = I - 2 \begin{bmatrix} S_1^2 & S_1 S_2 & \dots & S_1 S_n \\ S_2 S_1 & S_2^2 & \dots & S_2 S_n \\ \vdots & \vdots & \ddots & \vdots \\ S_n S_1 & S_n S_2 & \dots & S_n^2 \end{bmatrix}$$

$$= \begin{bmatrix} 1-2S_1^2 & -2S_1 S_2 & \dots & -2S_1 S_n \\ -2S_2 S_1 & 1-2S_2^2 & \dots & -2S_2 S_n \\ \vdots & \vdots & \ddots & \vdots \\ -2S_n S_1 & -2S_n S_2 & \dots & 1-2S_n^2 \end{bmatrix}$$

$$H \cdot \begin{bmatrix} \lambda \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} 1-2S_1^2 \lambda \\ -2S_1 S_2 \lambda \\ \vdots \\ -2S_n S_1 \lambda \end{bmatrix} = \begin{bmatrix} 1-2S_1^2 \\ -2S_2 S_1 \\ \vdots \\ -2S_n S_1 \end{bmatrix} \lambda = x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$\therefore S_1 x_1 = (1-2S_1^2) \lambda \Rightarrow S_1 = \sqrt{\frac{1}{2}(1 - \frac{x_1}{\lambda})}$$

$$x_i = -2S_i S_1 \lambda \quad (i=2, \dots, n) \quad S_i = -\frac{x_i}{2S_1 \lambda}$$

引理 2.4 $\forall \Phi \in R^{N \times n} \quad (N > n)$, $\exists$ 正交阵 P , 使得 $P\Phi = \begin{bmatrix} \bar{\Phi} \\ 0 \end{bmatrix}$, $\bar{\Phi} \in R^{n \times n}$ 为上三角阵; P 是 n 个 Householder 变换之积

$$\text{证: } P = H_n \cdot H_{n-1} \cdot \dots \cdot H_1, \quad P\Phi = H_n \cdot H_{n-1} \cdot \dots \cdot H_1 \cdot \Phi$$

$$\forall \Phi = [\Phi_1, \Phi_2, \dots, \Phi_n] \in R^{N \times n}$$

$\exists$ Householder 阵 H_i , 使得

$$H_i \Phi = [H_i \Phi_1, H_i \Phi_2, \dots, H_i \Phi_n]$$

$$= \begin{bmatrix} \lambda_1 & \phi'_{12} & \dots & \phi'_{1n} \\ 0 & \phi'_{22} & \dots & \phi'_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \phi'_{n2} & \dots & \phi'_{nn} \end{bmatrix}$$

$$\text{where } \lambda_i = \sqrt{\Phi_i^T \Phi_i}, \quad H = I - 2S_i S_i^T$$

$$\Phi = \begin{bmatrix} \phi_{11} & \phi_{12} & \dots & \phi_{1n} \\ \phi_{21} & \phi_{22} & \dots & \phi_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \phi_{n1} & \phi_{n2} & \dots & \phi_{nn} \end{bmatrix}$$

$$\exists H_2 = I - 2S_2 S_2^T, \quad S_2 = [S_{2,1}, S_{2,2}, \dots, S_{2,n}]^T$$

令 $S_{2,1} = 0, \quad S_{2,2}, \dots, S_{2,n}$ 由 $\phi'_{22}, \dots, \phi'_{2n}$ 生成

$$\text{则 } H_2 = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & \pm 1 & & \\ \vdots & & \ddots & \\ 0 & & & 1 \end{bmatrix}$$

$$\text{其中 } H_2 H_1 \Phi = \begin{bmatrix} \lambda_1 & \phi'_{12} & \dots & \phi'_{1n} \\ 0 & \lambda_2 & \phi'_{23} & \dots & \phi'_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \phi'_{n3} & \dots & \phi'_{nn} \end{bmatrix}$$

- ϕ'_{1n}, ϕ'_{2n} 代表另一个值, 是符号表示, 不是求导
- 科学研究目标是庞大的 (系统不确定性高的)
- $\Phi_N^T \Phi_N$: 信息矩阵, 表征了系统的信息量
- $(\Phi_N^T \Phi_N)^{-1}$: 协方差矩阵, 描述系统的不确定性

($N \gg n$)

定理 2.1

求解 $J(\theta) = (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$ 的最小二乘估计问题等于求解 $\bar{\theta} = \bar{Y}_1$, 其中 $\bar{Y}_1$ 由定理 2.1 ~ 2.3 定义, 则 $J(\theta) = \bar{Y}_2^T \bar{Y}_2$ $\hat{\theta} = \bar{\Phi}^{-1} \bar{Y}_1$

$$\hat{\theta} = \bar{\Phi}^{-1} \bar{Y}_1 \quad (1)$$

$$\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N \quad (2)$$

说明: ①式比②式在统计意义上要小误差, 要最优, 但并不代表在特殊条件下①式也比②式最优。统计意义指一万次实验, ①式的平均误差一定比②式小。

②主成分估计/分析法 (PCA)

$$\Phi_N^T \Phi_N \theta = \Phi_N^T Y_N \quad (\Phi_N^T \Phi_N \text{ 是对称正定阵})$$

$\exists P, P^T P = I$, 使得 $(P \text{ 可以用史密特正交化法求, 线性代数相似矩阵那讲了})$

$$P^T \Phi_N^T \Phi_N P = \text{diag} \{ \lambda_1, \dots, \lambda_n \}$$

where $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$ 为 $\Phi_N^T \Phi_N$ 的特征根。

$$\Rightarrow P^T \Phi_N^T \Phi_N \theta = P^T \Phi_N^T Y_N$$

$$\Leftrightarrow P^T \Phi_N^T \Phi_N P P^T \theta = P^T \Phi_N^T Y_N \quad \lambda_i \bar{\theta}_i = \bar{Y}_i$$

$$\Leftrightarrow P^T \theta = \bar{\theta} = [\bar{\theta}_1, \bar{\theta}_2, \dots, \bar{\theta}_n]^T$$

$$P^T \Phi_N^T Y_N = \bar{Y} \triangleq [\bar{y}_1, \bar{y}_2, \dots, \bar{y}_n]^T \quad \bar{Y}_i = \frac{\bar{y}_i}{\bar{\theta}_i}$$

$$\Rightarrow \text{diag} \{ \lambda_1, \lambda_2, \dots, \lambda_n \} \cdot \bar{\theta} = \bar{Y} \quad \bar{\theta}_i = \frac{\bar{y}_i}{\lambda_i}$$

$$\Leftrightarrow \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_p \\ & & & \lambda_{p+1} \\ & & & & \ddots \\ & & & & & \lambda_n \end{bmatrix} \begin{bmatrix} \bar{\theta}_1 \\ \vdots \\ \bar{\theta}_p \\ \bar{\theta}_{p+1} \\ \vdots \\ \bar{\theta}_n \end{bmatrix} = \begin{bmatrix} \bar{y}_1 \\ \vdots \\ \bar{y}_p \\ \bar{y}_{p+1} \\ \vdots \\ \bar{y}_n \end{bmatrix}$$

$$\text{Def: } P^T \theta = \bar{\theta} \Rightarrow \theta = P \bar{\theta}$$

若 $\Phi_N^T \Phi_N$ 不是病态, 则由上式可解得: $\bar{\theta}_i = \bar{y}_i / \lambda_i$, 而原正规方程参数 $\theta = P \bar{\theta}$

(因为 $P P^T = I$)。

当 $\Phi_N^T \Phi_N$ 为病态时, 某些特征根近似为零, 不妨设

$$\lambda_{p+1} = \dots = \lambda_n = 0$$

$$\text{其中 } \bar{\theta}_i = \frac{\bar{y}_i}{\lambda_i} \quad (i=1, 2, \dots, p) \quad \bar{\theta}_{p+1} = \dots = \bar{\theta}_n = 0$$

将正交矩阵 P 对应 p 也相应地分成两块: $P = (P_1, P_2)$, 则

$$\begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = P_1 \begin{bmatrix} \bar{y}_1 / \lambda_1 \\ \bar{y}_2 / \lambda_2 \\ \vdots \\ \bar{y}_p / \lambda_p \end{bmatrix}, \quad \theta_{p+1} = \theta_{p+2} = \dots = \theta_n = 0$$

这样得到的估计称作主成分估计。

$$y(k) = \sum \alpha_i u_i(k)$$

问题: 在做主成分估计时, p 究竟取多少呢?

$$y'(k) = \sum \alpha'_i u'_i(k)$$

$$\frac{\sum_{i=1}^p \lambda_i}{\sum_{i=1}^n \lambda_i} \geq 80\% \quad \checkmark$$

' 表示不同的值

书上补充:

(1) 正交变换实质上是将 Φ_N 中的列正交化。特征根的大小, 反映数据所提供的信息量的多少, 主成分估计保留信息量大的变量, 去掉信息量小的变量, 克服由于数据的相关性带来的求解困难, 与最小二乘估计相比, 具有更好的性质。

(2) 经验表明, 用 Householder 变换求最小二乘解一般比解正规方程精度要高。特别在病态严重时, 这一优点尤为突出。但当病态严重时, 解正规方程的方法无法求解, Householder 方法可得到众多解中的一个解, 但往往不是最小模解, 即可能有其他解, 而模比它还小, 这里的“模”是指“解向量的模”, 一般是指解向量的长度。主成分估计法可得到唯一的 最小模解。

对应的是病态最轻的解。

COLL 精度

§2.4 模型参数的极大似然估计 (ML)

1. 问题描述:

考虑 $y(k) = a_0 + a_1 u_1(k) + \dots + a_n u_n(k) + e(k)$

$$Y_N = [y(1), y(2), \dots, y(N)]^T$$

$$P(Y_N, \theta) = P(y(1), y(2), \dots, y(N), \theta) \quad P \text{ 表示概率}$$

$$\theta^* = \arg \max_{\theta} P(Y_N, \theta)$$

特别地, 当 $e(k)$ 为白噪声时, 意味着 $e(k)$ 是独立的, 那么 y 也是独立的。

(因为 y 和 $e(k)$ 分布类似, 只做了平移)

$$\text{则 } P(Y_N, \theta) = \prod_{k=1}^N P(y(k), \theta) \quad \text{在每个时刻都产生同一个 } y(k) = u_1(k), u_2(k) \dots u_n(k)$$

而这些 y 独立同分布
则 概率为所有乘积

2. 极大似然估计方法

$$y(k) = \sum a_i u_i(k) + e(k) = \Phi_k^T \theta + e(k)$$

$$Y_N = \Phi_N \theta + e_N$$

$$e_N \sim N(0, \Sigma) \quad \text{[即 } e_N \text{ 为 } 0 \text{ 均值高斯分布]} \quad \text{由于 } e_N \text{ 是 } 0 \text{ 均值高斯分布, 那么}$$

$$\text{在此基础上, 假设 } Y_N \sim N(\Phi_N \theta, \Sigma) \quad Y_N \text{ 也是高斯分布 } Y_N \sim N(\Phi_N \theta, \Sigma)$$

$$\text{则 } P(Y_N, \theta) = \left(\frac{1}{\sqrt{2\pi} \det(\Sigma)} \right)^N \exp \left\{ -\frac{1}{2} (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta) \right\}$$

补充说明:

1. $\exp$ 表示 e 的多少次方

2. $\arg \max$ 是一种函数, 函数 $y = f(x)$, $x_0 = \arg \max (f(x))$ 的意思是: 参数 x_0 满足 $f(x_0)$ 为 $f(x)$ 的最大值。

即: $\arg \max f(x)$ 是使得 $f(x)$ 取得最大值所对应的变量 x

同理: $\arg \min f(x)$ 是使得 $f(x)$ 取得最小值所对应的变量 x

3. 正态分布, 也称“常态分布”, 又名高斯分布。

若随机变量 X 服从一个数学期望为 μ , 方差为 σ^2 的正态分布, 记为 $N(\mu, \sigma^2)$

期望值 μ 决定了分布的位置, 标准差 σ 决定了分布的幅度。

当 $\mu=0, \sigma=1$ 时的正态分布是标准正态分布。

$$\text{其概率密度函数为: } f(x) = \frac{1}{\sqrt{2\pi} \sigma} \exp \left(-\frac{(x-\mu)^2}{2\sigma^2} \right)$$

课本上:

1. 由于系统受随机噪声干扰, 所以系统的输出 y 是随机的。对于给定的参数向量 θ , 输出 y 的分布密度记做 $P(y; \theta)$ 。若 $y(1) \dots y(N)$ 是独立的观测, 则它们的联合分布密度是 $L(y(1), \dots, y(N); \theta) = \prod_{k=1}^N P(y(k); \theta)$

$$\text{或 } L(Y_N; \theta) = \prod_{k=1}^N P(y(k); \theta)$$

L 称为似然函数。根据数理统计中最大似然原则可知, 使得 L 达到最大的参数估计 $\hat{\theta}$ 称为最大似然估计, 即 $\hat{\theta} = \hat{\theta}(Y_N)$, 使

$$L(Y_N; \hat{\theta}) = \max_{\theta} L(Y_N; \theta)$$

2. 矩阵微分

$$\frac{\partial}{\partial \Sigma} \log |\Sigma| = (\Sigma^{-1})^T$$

$$\frac{\partial}{\partial \Sigma} \text{tr} A \Sigma^{-1} B = -(\Sigma^{-1} B A \Sigma^{-1})^T$$

2017年11月2日

回顾: 病态方程的两种解法:


(1) Householder: $(\Phi_N^T \Phi_N) \theta = \Phi_N^T Y_N$

$$\Rightarrow \bar{\Phi}_N \theta = \bar{Y}$$

Householder 解法里的 $P_{\Phi_N} \rightarrow \bar{\Phi}$: P 不唯一, 导致 $\bar{\Phi}$ 不唯一, 病态程度也不同。

总之, Householder 虽然将病态减轻了, 但仍存在一定病态。

(2) 主成分估计法

只要去掉的 λ 足够多, 剩下的 λ 充分大, 则理论上是可以达到没有病态的。

2.4 极大似然估计 (Maximum Likelihood Estimate):

$$y(k) = a_0 + \sum_{i=1}^n a_i u_i(k) + e(k) \quad k=1, \dots, N$$

$$\{y(1), y(2), \dots, y(N)\}$$

必然可以用一分布来描述它: $P\{y(1), y(2), \dots, y(N), \theta\}$

$$\hat{\theta}^* = \arg \max_{\theta \in \Theta} P\{y(1), y(2), \dots, y(N)\}$$

假设 Y_N 服从高斯分布:

$$Y_N = [y(1), y(2), \dots, y(N)]^T \sim N(\Phi_N \theta, \Sigma)$$

$$P(Y_N; \theta) = (2\pi \det(\Sigma))^{-\frac{N}{2}} \exp\left\{-\frac{1}{2} (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta)\right\}$$

特别地, 当 $e(k) \sim N(0, \sigma^2)$ 白噪声则 $y(k) \sim N(\phi_k^T \theta, \sigma^2)$ 独立地

$$Y_N \sim N(\Phi_N \theta, \sigma^2 I)$$

$$P(Y_N; \theta) = \prod_{k=1}^N p(y(k); \theta)$$

$$\text{where } p(y(k); \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2} (y(k) - \phi_k^T \theta)^2}$$

$$P(Y_N; \theta) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N \exp\left\{-\frac{1}{2\sigma^2} \sum_{k=1}^N [y(k) - \phi_k^T \theta]^2\right\}$$

$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N \exp\left\{-\frac{1}{2\sigma^2} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)\right\}$$

2. 求解

$$\text{考虑 } P(Y_N; \theta) = [2\pi \det(\Sigma)]^{-\frac{N}{2}} \exp\left\{-\frac{1}{2} (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta)\right\}$$

① 当 Σ 已知时, 最大似然与最小二乘等价

$$\max P(Y_N; \theta) \Leftrightarrow \min (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta) \quad \text{加权最小二乘}$$

$$\text{令 } J(\theta) = (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta)$$

$$\text{令 } \frac{\partial J}{\partial \theta} = -2 \Phi_N^T \Sigma^{-1} (Y_N - \Phi_N \theta) = 0$$

$$\Leftrightarrow \Phi_N^T \Sigma^{-1} \Phi_N \theta = \Phi_N^T \Sigma^{-1} Y_N$$

$$\Leftrightarrow \hat{\theta} = (\Phi_N^T \Sigma^{-1} \Phi_N)^{-1} \Phi_N^T \Sigma^{-1} Y_N$$

② 当 Σ 未知时假设 Σ 与 θ 无关, 但不排除有关; Σ 是与白噪声特性有关

$$\log p(Y_N; \theta) = -\frac{N}{2} (\log 2\pi + \log \det(\Sigma)) - \frac{1}{2} (Y_N - \Phi_N \theta)^T \Sigma^{-1} (Y_N - \Phi_N \theta)$$

让 $\log p(Y_N; \theta)$ 分别对 θ 和 Σ 求偏导可得:

Σ 是对称阵

$$\begin{cases} \frac{\partial \log P}{\partial \theta} = \Phi_N^T \Sigma^{-1} (Y_N - \Phi_N \theta) = 0 \end{cases} \quad \text{一个标量对向量求导是雅克比}$$

$$\begin{cases} \frac{\partial \log P}{\partial \Sigma} = -\frac{N}{\Sigma} \Sigma^{-1} + \frac{1}{\Sigma} \Sigma^{-1} (Y_N - \Phi_N \theta) (Y_N - \Phi_N \theta)^T \Sigma^{-1} = 0 \end{cases}$$

$$\Rightarrow \begin{cases} \hat{\theta} = (\Phi_N^T \Sigma^{-1} \Phi_N)^{-1} \Phi_N^T \Sigma^{-1} Y_N \\ \hat{\Sigma} = \frac{1}{N} (Y_N - \Phi_N \hat{\theta}) (Y_N - \Phi_N \hat{\theta})^T \end{cases}$$

解阵

陪第

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

非0

分析: 由一个标量的最大, 最小化去反解一个 n 维向量或 $n \times n$ 矩阵的最大, 最小化, 无其他任何约束条件, 可以解吗?

答: 不可以, 因为只有目标函数, 没有约束关系, 解不出来。

$$\text{就像 } f(x, y) = ax^2 + by^2 + c \rightarrow \min$$

$$\text{只能解出 } (x, y) = 0 \quad x = g(y) \quad y = h(x)$$

而解不出具体的 x 和 y 的值。

因此①式并没有真正求出 $\hat{\theta}$ 和 $\hat{\Sigma}$, 因为 $\hat{\theta}$ 中含有 $\hat{\Sigma}$, $\hat{\Sigma}$ 中也含有 $\hat{\theta}$ 。

解的时候只能猜出 $\hat{\Sigma}(0) \rightarrow \hat{\theta}(0) \rightarrow \hat{\Sigma}(1) \dots$

直到 $\hat{\theta}$ 和 $\hat{\Sigma}$ 保持相对稳定, 不再变化明显为止。

特例:

$$Y_N \sim N(\Phi_N \theta, \sigma^2 I) \quad \text{高斯分布}$$

$$P(Y_N; \theta) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N \exp \left\{ -\frac{1}{2\sigma^2} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta) \right\}$$

标准最小二乘, 解 $\theta = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$

当 σ^2 已知时,

$$\max P \Leftrightarrow \min (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

当 σ^2 未知时,

$$\log P = -N \log \sqrt{2\pi} - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta) - \frac{N}{2} \log \sigma^2$$

$$\frac{\partial \log P}{\partial \theta} = \frac{1}{\sigma^2} \Phi_N^T (Y_N - \Phi_N \theta) = 0$$

$$\Rightarrow \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$$

$$\frac{\partial \log P}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta) = 0$$

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{N} (Y_N - \Phi_N \hat{\theta})^T (Y_N - \Phi_N \hat{\theta})$$

MLE vs LSE:

主要

区别

可

当 $e(k)$ 为高斯白噪声时 $\hat{\theta}: \text{LSE} \Leftrightarrow \text{MLE}$ 二者等价

$\hat{\sigma}^2: \text{LSE} \neq \text{MLE}$ $\left\{ \begin{array}{l} \text{极大似然给出的估计是有偏的} \\ \text{最小二乘给出的估计是无偏的} \end{array} \right.$

当 $e(k)$ 为非独立的噪声, MLE $\checkmark$

第三章 离散线性动态模型的辨识

§3.1 引言

动态: 当前时刻系统的输出取决于当前输入和历史输入 $y(n)$ 到 $y(1)$

$$y(n+k) = -\sum_{i=1}^n a_i y(n+k-i) + \sum_{i=1}^n b_i u(n+k-i) + e(n+k) \quad n \text{ 阶系统}$$

$$e(n+k) \sim N(0, \sigma^2) \quad \text{白噪声}$$

$$\{y(n+k), u(n+k-i), k=1, 2, \dots, N\}$$

$$\{a_1, \dots, a_n, b_1, \dots, b_n\}$$

$$J(a_1, \dots, a_n, b_1, \dots, b_n) \triangleq \sum_{k=1}^N e^2(n+k)$$

$$= \sum_{k=1}^N \left\{ y(n+k) - \left[-\sum_{i=1}^n a_i y(n+k-i) + \sum_{i=1}^n b_i u(n+k-i) \right] \right\}^2$$

$$(\hat{a}_i, \hat{b}_i) = \arg \min_{a_i, b_i} J \quad \begin{array}{l} \text{真实系统输出} \\ \text{模型系统输出} \end{array}$$

6

单独输入单独输出

但是此刻的输入和历史的输入

输出有关, 所以要用到前次

§ 3.3 递推最小二乘法

课本上:

理论上等价

上一节给出的最小二乘估计式和加权最小二乘估计式是基于全部数据一次处理得到的, 因此称此算法是一次完成最小二乘法。对于线性定常系统来说, 数据越多, 估计量的精确度就越高。但是, 若采用一次完成的算法就需要存储大量数据, 这不仅要占计算机的大量内存, 而且随着数据的增加, 计算时间也越来越长。另外, 一次完成算法也不能满足在线辨识的要求。为解决以上矛盾, 提出了最小二乘估计的递推算法。自校正需要一边估计一边控制

递推算法的基本思想是: 每取得一个新数据, 就根据新数据对原估计量进行修正, 从而得到(改善的)新估计量, 而不是将新数据加到老数据中重新计算。为得到递推算法, 先看一下增加新数据后最小二乘估计有何变化。

课堂笔记:

1. 问题的提出

$$k = n + N \quad \hat{\theta}_N \quad n: \text{开始时刻}$$

$$k = n + N + 1 \quad y(n + N + 1) \quad \hat{\theta}_{N+1} = \hat{\theta}_N + \Delta \hat{\theta} \quad \text{该修正值取决于当前输出}$$

核心就是建立 $\hat{\theta}_{N+1}$ 与 $\hat{\theta}_N$ 之间的关系

2. 递推最小二乘算法

考虑 WLS (加权最小二乘)

$$\hat{\theta}_{N+1} = (\Phi_{N+1}^T W_{N+1} \Phi_{N+1})^{-1} (\Phi_{N+1}^T W_{N+1} Y_{N+1})$$

$$\hat{\theta}_N = (\Phi_N^T W_N \Phi_N)^{-1} (\Phi_N^T W_N Y_N)$$

P_N

不确定性比上一次减小, 估计误差不一定取决于噪声

§ 3.2 最小二乘估计

$$\phi_k = [-y(n+k-1) \dots -y(n+k-1), u(n+k-1) \dots u(n+k-1)]^T$$

$$\theta = [a_1 \dots a_n, b_1 \dots b_n]^T$$

$$y(n+k) = \phi_k^T \theta + e(n+k) \quad k=1, 2, \dots, N$$

$$\Phi_N = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix} = \begin{bmatrix} -y(n) & \dots & -y(n) & u(n) & \dots & u(n) \\ -y(n+1) & \dots & -y(n+1) & u(n+1) & \dots & u(n+1) \\ \vdots & & \vdots & & & \vdots \\ -y(n+N) & \dots & -y(n+N) & u(n+N) & \dots & u(n+N) \end{bmatrix}$$

动态模型的动态特性可能比静态严重

$$Y_N = [y(n+1) \dots y(n+N)]^T$$

$$e_N = [e(n+1) \dots e(n+N)]^T$$

$$Y_N = \Phi_N \theta + e_N$$

对递推的这种

$$J(\theta) = \sum_{k=1}^N e^2(n+k) = e_N^T e_N$$

$$= (Y_N - \Phi_N \theta)^T (Y_N - \Phi_N \theta)$$

$$\frac{\partial J}{\partial \theta} = 0 \Rightarrow \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N \quad (1)$$

称 $\hat{\theta}$ 为 θ 的最小二乘估计

① 意味着对所有数据的地位都是平等的。但在一些情况下, 某些数据比较重要, 应当特别重视, 这就需要对它们区别对待, 在性能指标中体现为对残差的不同加权值, 加权越大表示对相应的数据越重视。(WLS)

加权法

$$J(\theta) = \sum_{k=1}^N w_k e^2(n+k) = e_N^T W_N e_N \quad \text{静态模型和动态模型都可以加权}$$

$$W_N = \text{diag} \{w_1, \dots, w_N\}$$

$$\hat{\theta} = (\Phi_N^T W_N \Phi_N)^{-1} \Phi_N^T W_N Y_N$$

$$\Phi_{N+1} = \begin{bmatrix} \Phi_N \\ \phi_{N+1}^T \end{bmatrix} \quad W_{N+1} = \begin{bmatrix} W_N & 0 \\ 0 & w_{N+1} \end{bmatrix} \quad Y_{N+1} = \begin{bmatrix} Y_N \\ y(n+N+1) \end{bmatrix}$$

$$P_{N+1} = (\Phi_{N+1}^T W_{N+1} \Phi_{N+1})^{-1}$$

$$= \left(\begin{bmatrix} \Phi_N^T \\ \phi_{N+1}^T \end{bmatrix} \begin{bmatrix} W_N & 0 \\ 0 & w_{N+1} \end{bmatrix} \begin{bmatrix} \Phi_N \\ \phi_{N+1} \end{bmatrix} \right)^{-1}$$

$$= (\Phi_N^T W_N \Phi_N + \phi_{N+1}^T w_{N+1} \phi_{N+1})^{-1}$$

$$= (P_N^{-1} + \phi_{N+1}^T w_{N+1} \phi_{N+1})^{-1} \iff P_N^{-1} = P_{N+1}^{-1} - \phi_{N+1}^T w_{N+1} \phi_{N+1}$$

$$\begin{aligned} ((A+HBH^T)^{-1} &= A^{-1} - A^{-1}H(H^T A^{-1}H + B^{-1})^{-1}H^T A^{-1} \\ &= P_N - P_N \phi_{N+1} (\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1})^{-1} \phi_{N+1}^T P_N \end{aligned}$$

$$= P_N - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}}$$

P_N 是正定阵， $\phi_{N+1}^T \phi_{N+1}$ 是标量， $xx^T \geq 0$

$$\leq P_N$$

$$\hat{\theta}_{N+1} = P_{N+1} \Phi_{N+1}^T W_{N+1} Y_{N+1}$$

$$= P_{N+1} \left(\begin{bmatrix} \Phi_N^T \\ \phi_{N+1}^T \end{bmatrix} \begin{bmatrix} W_N & 0 \\ 0 & w_{N+1} \end{bmatrix} \begin{bmatrix} Y_N \\ y(n+N+1) \end{bmatrix} \right)$$

$$= P_{N+1} [\Phi_N^T W_N Y_N + \phi_{N+1}^T w_{N+1} y(n+N+1)]$$

$$= P_{N+1} [P_N^{-1} \hat{\theta}_N + \phi_{N+1}^T w_{N+1} y(n+N+1)]$$

$$= P_{N+1} [(P_N^{-1} - \phi_{N+1}^T w_{N+1} \phi_{N+1}) \hat{\theta}_N + \phi_{N+1}^T w_{N+1} y(n+N+1)]$$

$$= \hat{\theta}_N + P_{N+1} \phi_{N+1}^T w_{N+1} [y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N]$$

$$= \hat{\theta}_N + \left(P_N - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}} \right) \phi_{N+1}^T w_{N+1} [y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N]$$

$$\hat{\theta}_{N+1} = \hat{\theta}_N + \Delta \theta$$

$\Delta \theta$ ← $y(n+N+1)$

$$= \hat{\theta}_N + \frac{[P_N (\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}) - P_N \phi_{N+1} \phi_{N+1}^T P_N] \phi_{N+1}^T w_{N+1} [y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N]}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}}$$

$$= \hat{\theta}_N + \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N \phi_{N+1}^T w_{N+1} [y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N]}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}} - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N \phi_{N+1}^T w_{N+1} \phi_{N+1}^T \hat{\theta}_N}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}}$$

是标量，顺序无所谓

$$= \hat{\theta}_N + \frac{P_N \phi_{N+1}}{\phi_{N+1}^T P_N \phi_{N+1} + w_{N+1}^{-1}} [y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N]$$

从输出空间到参数空间的反投影

$$\text{分析: } y(n+N+1) = \phi_{N+1}^T \theta_{N+1}$$

$$\therefore \phi_{N+1}^T \hat{\theta}_N = \hat{y}(n+N+1|n+N) \quad \text{用当前时刻 } (n+N) \text{ 预测下一时刻输出。}$$

$$y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N = \Delta y \text{ 或 } \tilde{y} \quad \begin{cases} \tilde{\theta} = \theta - \hat{\theta}_N \\ e(n+1) \end{cases}$$

在统计意义上，修正后的结果肯定会比修正前好。

$$P_{N+1} = (\Phi_{N+1}^T W_{N+1} \Phi_{N+1})^{-1} \propto P_N$$

→ 表征了对 θ 估计的不确定性。值大，说明不准，小则准。

课本上：

$\phi_{N+1}^T \hat{\theta}_N$ 是在 $(n+N)$ 次测量基础上对第 $(n+N+1)$ 次输出 $y(n+N+1)$ 的预测，当实际测得 $y(n+N+1)$ 后，它与预测估计之间有一偏差

$$y(n+N+1) - \phi_{N+1}^T \hat{\theta}_N$$

称为预测偏差，这个偏差一方面说明实际过程与原模型之间存在误差，另一方面也体现了新的量测对参数带来的新信息。因此，新的参数估计值应根据这一偏差对原估计值进行修正。

滤波 - 去噪 - 平滑

2017年11月9日

二阶线性系统


- PID 控制器。用于跟踪问题，还可以用预测控制，或现代控制里的最优控制。

5.3.4 卡尔曼滤波器 (Kalman Filter)

一是线性系统在最小二乘意义下的最优观测器

基于模型的

卡尔曼: Rudolf E. Kalman



Bayesian Filter 贝叶斯滤波器

假设已知初始分布 $x_0 \sim p(x_0)$

过程模型 process model $p(x_k | x_{k-1})$

观测模型 $p(y_k | x_k)$

$$x = \Phi x + \psi u \quad x(k+1) = A x(k) + B u(k)$$

$$y = C x + D \quad \text{能看到什么东西取决于站的位置}$$

$p(x_k | y_{1:k})$ 通过 x 的动态变化, 得到 y 的值, 就可以反推出 x

$p(x_{0:k} | y_{1:k})$ 维数太高

贝叶斯滤波:

① Prediction: $p(x_k | y_{1:k-1}) \rightarrow p(x_k | y_{1:k-1})$
(k-1)+n step 无噪声 (k-1) 时刻

② Update $p(x_k | y_{1:k-1}) \rightarrow p(x_k | y_{1:k})$
(k时刻) y_k 过程模型 posterior of (k-1) step

$$p(x_k | y_{1:k-1}) = \int p(x_k | x_{k-1}) \cdot p(x_{k-1} | y_{1:k-1}) dx_{k-1}$$

$$p(x_k | y_{1:k}) = p(x_k | y_{1:k-1}, y_k) = \underbrace{p(y_k | x_k)}_A \cdot \underbrace{p(x_k | y_{1:k-1})}_B \cdot \underbrace{p(x_k)}_{\text{是一个常值}}$$

$$\begin{aligned} &= p(y_k | x_k) \cdot p(x_k | y_{1:k-1}) \\ &= p(y_k | x_k) \int p(x_k | x_{k-1}) p(x_{k-1} | y_{1:k-1}) dx_{k-1} \end{aligned}$$

贝叶斯概率公式: $p(A/B) = \frac{p(B/A) \cdot p(A)}{p(B)}$
B是条件, 是个常值

卡尔曼滤波解决线性高斯系统

考虑 $x(k+1) = A(k) x(k) + B(k) u(k)$ ① 离散 考虑线性动态系统
 $y(k+1) = C(k+1) x(k+1) + D(k+1) v(k+1)$ ② 取用于静态模型

一般情况下, $D(k+1) = I$

假设 W, V 都是高斯白噪声:

$$E(W(k)) = E(V(k)) = 0 \quad 0 \text{均值高斯系统}$$

$W(k), V(k)$ 表示过程/测量噪声, 相互独立的, 不相关
系统输入 输出

$A(k), B(k), C(k+1)$ 已知

方差 $E(W(k)W^T(k)) = Q(k)$ $W \sim N(0, Q)$ 未知

方差 $E(V(k)V^T(k)) = R(k)$ $V \sim N(0, R)$ 知道

定义: $\hat{x}(k|k)$: ^(当前) K时刻对K时刻的系统状态估计

$\hat{x}(k+1|k)$: 站在K时刻, 对k+1时刻的系统状态估计, 预测

$\tilde{x}(k|k) \triangleq x(k) - \hat{x}(k|k)$ 系统估计误差

$\tilde{x}(k+1|k) \triangleq x(k+1) - \hat{x}(k+1|k)$ 系统状态估计误差

$P(k|k) \triangleq E[\tilde{x}(k|k) \cdot \tilde{x}^T(k|k)]$ $x(k|k)$ 的协方差

$P(k+1|k) \triangleq E[\tilde{x}(k+1|k) \cdot \tilde{x}^T(k+1|k)]$ 对系统状态预测的协方差 (统计意义的误差)

① 预测 (K时刻) 假设上时刻 $\hat{x}(k|k)$ $P(k|k)$ 已知

$\hat{x}(k|k) \rightarrow \hat{x}(k+1|k)$ ~~$x(k+1|k) = A(k) \hat{x}(k|k)$~~

状态预测: $\hat{x}(k+1|k) = A(k) \hat{x}(k|k)$ 代入上页①或②, 可知 $W(k)$ 的值为0

预测解决的是 $p(x_k | y_{1:k}) \rightarrow p(x_{k+1} | y_{1:k})$

斜方差预测: $P(k+1|k) = E[x(k+1|k) - \hat{x}(k+1|k)] \cdot [x(k+1|k) - \hat{x}(k+1|k)]^T$

即 $\tilde{x}$

$= E[A(k)x(k) + B(k)W(k) - A(k)\hat{x}(k|k)] [A(k)x(k) + B(k)W(k) - A(k)\hat{x}(k|k)]^T$

$= E[A(k)\tilde{x}(k|k) + B(k)W(k)] [A(k)\tilde{x}(k|k) + B(k)W(k)]^T$

k时刻系统状态估计误差

$= A(k) E[\tilde{x}(k|k) \tilde{x}^T(k|k)] A^T(k) + B(k) E[W(k)W^T(k)] B^T(k)$

$+ A(k) E[\tilde{x}(k|k) W^T(k)] B^T(k) + B(k) E[W(k) \tilde{x}^T(k|k)] A^T(k)$

$= A(k) P(k|k) A^T(k) + B(k) Q(k) B^T(k)$

先验信息: 是预测的, 还没有实际输出, 不需要任何外部信息;

② 后验信息: 需根据外部信息

② 更新 (k+1时刻) $y(k+1)$ 传感器测量的系统输出

$\hat{x}(k+1|k) \xrightarrow{y(k+1)} \hat{x}(k+1|k+1)$

$\hat{y}(k+1|k) = C(k+1) \hat{x}(k+1|k)$ 代入上页①后得到

$\tilde{y}(k+1|k) \triangleq y(k+1) - \hat{y}(k+1|k)$

出现新息的原因: $\begin{cases} V(k+1) \\ W(k) \\ \tilde{x}(k|k) \end{cases}$ 两个噪声 } 都未知, 三者相加形成了新息。
 $\tilde{x}(k|k)$ 一个状态

★ $\hat{x}(k+1|k+1) = \hat{x}(k+1|k) + \underbrace{W(k+1)}_{\text{增益矩阵, 是一个系数(权)}} \underbrace{\tilde{y}(k+1|k)}_{\text{新息}} ?$

$\begin{cases} x: \text{状态空间} \\ y: \text{观测空间} \end{cases} \Rightarrow W(k+1): \text{状态空间到观测空间的逆投影}$

卡尔曼给出了一个最优的 $W(k+1)$

$W^*(k+1) = \arg \min P(k+1|k+1)$

$P(k+1|k+1) = E[\tilde{x}(k+1|k+1) \tilde{x}^T(k+1|k+1)]$

$\tilde{x}(k+1|k+1) = x(k+1) - \hat{x}(k+1|k+1)$

$= x(k+1) - \hat{x}(k+1|k) - W(k+1) [y(k+1) - \hat{y}(k+1|k)]$

$= \tilde{x}(k+1|k) - W(k+1) [C(k+1) \tilde{x}(k+1|k) + V(k+1)]$

$= [I - W(k+1) C(k+1)] \tilde{x}(k+1|k) - W(k+1) V(k+1)$

• $\tilde{x}$ 和 $\hat{x}$ 的斜方差一样 斜方差: $\tilde{x} \cdot \tilde{x}^T$

• $\triangleq$: 表示定义 矩阵中用一个矩阵乘以它的转置表示平方

$$P(k+1|k+1) = E \{ [I - w(k+1)C(k+1)] \tilde{x}(k+1|k) - w(k+1)V(k+1) \}^T$$

$$\begin{aligned} &= [I - w(k+1)C(k+1)] E \{ \tilde{x}(k+1|k) \tilde{x}^T(k+1|k) \} [I - w(k+1)C(k+1)]^T \\ &\quad + w(k+1) E \{ V(k+1) V^T(k+1) \} w^T(k+1) \\ &\quad - [I - w(k+1)C(k+1)] E \{ \tilde{x}(k+1|k) V^T(k+1) \} w^T(k+1) \end{aligned}$$

$$= 0$$

$$\begin{aligned} &- w(k+1) E \{ V(k+1) \tilde{x}^T(k+1|k) \} [I - w(k+1)C(k+1)]^T \\ &= 0 \end{aligned}$$

$$= [I - w(k+1)C(k+1)] P(k+1|k) [I - w(k+1)C(k+1)]^T + w(k+1)R(k)w^T(k+1)$$

$$= P(k+1|k) + w(k+1)C(k+1)P(k+1|k)C^T(k+1)w^T(k+1) - w(k+1)C(k+1)P(k+1|k)$$

$$- P(k+1|k)C^T(k+1)w^T(k+1) + w(k+1)R(k+1)w^T(k+1)$$

$$= P(k+1|k) + w(k+1)[C(k+1)P(k+1|k)C^T(k+1) + R(k+1)]w^T(k+1)$$

$$- [w(k+1)C(k+1)P(k+1|k) + P(k+1|k)C^T(k+1)w^T(k+1)]$$

$$C(k+1)P(k+1|k)C^T(k+1) + R(k+1) = S(k+1) \triangleq \bar{S}(k+1)\bar{S}^T(k+1)$$

新息的统计误差(平均误差)

S 新息的协方差

$$E \{ C(k+1)P(k+1|k) \} = \bar{S}(k+1)E(k+1)$$

$$\Leftrightarrow E(k+1) = \bar{S}^T(k+1)C(k+1)P(k+1|k)$$

$$P(k+1|k+1) = P(k+1|k) + w(k+1)\bar{S}(k+1)\bar{S}^T(k+1)w^T(k+1) - w(k+1)\bar{S}(k+1)E(k+1)$$

$$- E^T(k+1)\bar{S}^T(k+1)w^T(k+1)$$

$$= P(k+1|k) + [w(k+1)\bar{S}(k+1) - E^T(k+1)] [w(k+1)\bar{S}(k+1) - E^T(k+1)]^T$$

$$- E^T(k+1)E(k+1)$$

③

当 $w(k+1) = E^T(k+1)\bar{S}^T(k+1)$ 时

$$\text{③式} = P(k+1|k)C^T(k+1)[\bar{S}^T(k+1)]^T\bar{S}^T(k+1)S^T(k+1)$$

$$= P(k+1|k)C^T(k+1)S^T(k+1)$$

$$P(k+1|k)_{\min} = P(k+1|k) - E^T(k+1)E(k+1)$$

$$\langle P(k+1|k) \rangle = P(k+1|k) - P(k+1|k)C^T(k+1)[\bar{S}^T(k+1)]^T\bar{S}^T(k+1)C(k+1)P(k+1|k)$$

$$= P(k+1|k) - P(k+1|k)C^T(k+1)S^T(k+1)C(k+1)P(k+1|k)$$

$$\leq P(k+1|k)$$

$$\leq P(k|k)$$

实际 $\begin{cases} x(k+1) = A(k)x(k) + u(k) \end{cases}$

观测的 $\begin{cases} y(k+1) = C(k+1)x(k+1) + v(k+1) \end{cases}$

预测 $\begin{cases} x(k+1|k) = A(k)x(k|k) \end{cases}$

估计 $\begin{cases} y(k+1|k) = C(k+1)x(k+1|k) \end{cases}$

卡尔曼:

$$x(k+1|k+1) = x(k+1|k) + w(k+1)[y(k+1) - C(k+1)x(k+1|k)]$$

$$w(k+1) = P(k+1|k+1) \cdot C(k)$$

$$P(k+1|k+1) = E \{ [\tilde{x}(k+1|k+1) \tilde{x}^T(k+1|k+1)] \}$$

$$C(k) = E \{ [\tilde{S}(k+1) \tilde{S}^T(k+1)] \}$$

2017年11月16日

PPT上:

卡尔曼滤波过程分为四步:

① 预测 (k时刻)

$$\hat{x}(k+1|k) = \Phi(k) \hat{x}(k|k)$$

$$P(k+1|k) = \Phi(k) P(k|k) \Phi^T(k) + \Gamma(k) Q(k) \Gamma^T(k)$$

② 更新 (k+1时刻)

$$\hat{x}(k+1|k+1) = \hat{x}(k+1|k) + w(k+1) [y(k+1) - H(k+1) \hat{x}(k+1|k)]$$

$$P(k+1|k+1) = P(k+1|k) - w(k+1) H^T(k+1) P(k+1|k)$$

其中, $w(k+1)$ 为卡尔曼增益矩阵.

$P(k+1|k)$ 一 对称方差预测

$$Y_N = \Phi_N \theta + e_N$$

$$y(k) = \phi(k)^T \theta + e(k)$$

↓
测量

→ 来自PPT上

$$\hat{x}(k+1) = \Phi(k) \hat{x}(k) + \Gamma(k) w(k) \quad \text{process model}$$

$$y(k+1) = H(k+1) \hat{x}(k+1) + v(k+1) \quad \text{observation model}$$

$$\theta(k+1) = \theta(k)$$

例: 室温估计 — 卡尔曼滤波器的一个实例

假设室内温度恒定, 使用温度传感器每隔1分钟对室温进行一次测量, 共测量100次.

$$\text{模型: } \begin{cases} x(k+1) = x(k) \\ y(k+1) = x(k+1) + v(k+1) \end{cases}$$

$$y(k+1) = x(k+1) + v(k+1)$$

设 $v(k) \sim N(0, \sigma^2)$ 0均值高斯分布

Date: / /

第一次

第二次

$$w(k+1) = P(k+1|k) A^T(k+1) [A(k+1) P(k+1|k) A^T(k+1) + R(k+1)]^{-1}$$

$H(k+1)$ 是一个单位阵

$$\begin{cases} y(1) \\ \sigma^2(1) \end{cases}$$

$$\begin{cases} y(2) \\ \sigma^2(2) \end{cases}$$

$$\begin{cases} \hat{x}_1 = y(1) \\ \hat{\sigma}_1^2 = \sigma^2(1) \end{cases}$$

$$\begin{cases} \hat{x}_2 = y(1) + w [y(2) - y(1)] \\ \hat{\sigma}_2^2 = \sigma^2(1) \end{cases}$$

$$= y(1) + \sigma^2(1) [\sigma^2(1) + \sigma^2(2)]^{-1} [y(2) - y(1)]$$

$$= y(1) + \frac{\sigma^2(1) [y(2) - y(1)]}{\sigma_0^2 + \sigma_2^2}$$

$$= \frac{\sigma_0^2 y(1) + \sigma_2^2 y(2)}{\sigma_0^2 + \sigma_2^2}$$

$$= \frac{\sigma_0^2}{\sigma_0^2 + \sigma_2^2} y(1) + \frac{\sigma_2^2}{\sigma_0^2 + \sigma_2^2} y(2)$$

$$\hat{\sigma}_2^2 = \sigma_0^2 - \sigma_0^2 [\sigma_0^2 + \sigma_2^2]^{-1} \sigma_2^2$$

$$= \sigma_0^2 \frac{\sigma_0^2}{\sigma_0^2 + \sigma_2^2}$$

$$= \frac{\sigma_0^2 \cdot \sigma_2^2}{\sigma_0^2 + \sigma_2^2} \leftarrow \begin{cases} \sigma_0^2 \\ \sigma_2^2 \end{cases}$$

第三次

目标跟踪 — 模型

$$x(k+1) = f(x(k), u(k), w(k)) \quad \text{对 } x \text{ 求导 } \frac{\partial f}{\partial x} \bigg|_{\hat{x}(k|k)} = \Phi \quad \frac{\partial f}{\partial w} \bigg|_{w=0} = \Gamma$$

$$y(k+1) = h(x(k+1)) + v(k+1) \quad \text{对 } y \text{ 求导 } \frac{\partial h}{\partial x} \bigg|_{\hat{x}(k+1|k)} = H$$

$$P(x_t | y_{1:t}) \propto P(y_t | x_t) \int P(x_t | x_{t-1}) P(x_{t-1} | y_{1:t-1}) dx_{t-1}$$

高斯系统	Gaussian	Linear (线性)	Independent (独立的)	KF (卡尔曼滤波)
			dependent (相关的)	CI
	non-linear (非线性)		Independent	EKF / IKF
			dependent	无意义

Non-Gaussian

Kalman Filter 卡尔曼滤波

Extended Kalman Filter 扩展的卡尔曼滤波

Information Filter

Sampling - Particle Filter
抽样 粒子 滤波器

最小二乘是卡尔曼滤波器的一个特例。从条件上，都是线性、高斯、独立的，而且还都是在最小二乘意义下的。

$$w^*(k+1) = \arg \min P(k+1|k+1)$$

$$E[\tilde{x}(k+1|k+1) \tilde{x}^T(k+1|k+1)]$$

问：为什么说最小二乘是卡尔曼滤波器的一个特例？

卡尔曼滤波解决的是状态估计问题，转移矩阵是单位阵，参数 θ 是常值，无状态转移，无噪声。

极大似然是最小二乘的一般化表示，但不要求高斯，不要求线性。

极大似然 > 贝叶斯滤波

→ 对极大似然的参数估计

Date: / /

§ 3.5 时变系统的参数辨识

1. 问题的提出

由于参数是随时间变化的，历史越久远的数据对当前数据估计的影响很小。

故可以采用加权：久远的数据占权值小，近的数据占权值大。

剔除：去掉旧数据，保留新数据。

若是线性高斯系统，也可以采用卡尔曼滤波，需写出参数 θ 。

2. 渐消记忆法 (加权)

考虑： $y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + e(n+k)$

$$\theta = [a_1, \dots, a_n, b_1, \dots, b_n]^T \text{ 时变}$$

$$J(\theta) = \sum_{k=0}^N e^2(n+k)$$

$k=N$ 时， $e(n+1)$ 对 $\theta(n)$ 的影响很小。

$$J(\theta) = \sum_{k=0}^N w_k e^2(n+k) \quad w_k \in (0, 1]$$

$$= e_N^T W_N e_N \quad \text{将权值设为遗忘因子}$$

$$w_k = p^{N-k} \quad 0 < p < 1$$

对加权最小二乘 WLS 来说：

$$\hat{\theta}_N = (\Phi_N^T W_N \Phi_N)^{-1} (\Phi_N^T W_N Y_N)$$

$$\hat{\theta}_{N+1} = (\Phi_{N+1}^T W_{N+1} \Phi_{N+1})^{-1} (\Phi_{N+1}^T W_{N+1} Y_{N+1})$$

$$\Phi_{N+1} = \begin{bmatrix} \Phi_N \\ \phi_{N+1}^T \end{bmatrix} \quad W_{N+1} = \begin{bmatrix} p \cdot W_N & 0 \\ 0 & 1 \end{bmatrix} \quad Y_{N+1} = \begin{bmatrix} Y_N \\ y(n+N+1) \end{bmatrix}$$

$$W_N = \text{diag}\{w_1, w_2, \dots, w_N\} = \begin{bmatrix} p^{N-1} & & \\ & \ddots & \\ & & 1 \end{bmatrix}$$

$$W_{N+1} = \text{diag}\{w_1, w_2, \dots, w_N, w_{N+1}\} = \begin{bmatrix} p^N & & \\ & \ddots & \\ & & 1 \end{bmatrix}$$

$$\hat{\theta}_{N+1} = (\Phi_{N+1}^T W_{N+1} \Phi_{N+1})^{-1} \cdot P_0 \quad P_{N+1}^{-1} - \text{信息}$$

$$= \left(\begin{bmatrix} \Phi_N \\ \phi_{N+1}^T \end{bmatrix}^T \begin{bmatrix} P \cdot W_N & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \Phi_N \\ \phi_{N+1}^T \end{bmatrix} \right)^{-1}$$

$$= (P \Phi_N^T W_N \Phi_N + \phi_{N+1} \phi_{N+1}^T)^{-1}$$

$$= P^{-1} (\Phi_N^T W_N \Phi_N + P^{-1} \phi_{N+1} \phi_{N+1}^T)^{-1}$$

$$= P^{-1} (P_N^{-1} + P^{-1} \phi_{N+1} \phi_{N+1}^T)^{-1}$$

$$\text{矩阵求逆公式: } (A + HBH^T)^{-1} = A^{-1} - A^{-1}H(H^T A^{-1}H + B^{-1})^{-1}H^T A^{-1}$$

$$= P^{-1} [P_N - P_N \phi_{N+1} (\phi_{N+1}^T P_N \phi_{N+1} + P)^{-1} \phi_{N+1}^T P_N]$$

$$= P^{-1} \left(P_N - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + P} \right)$$

$$\hat{\theta}_{N+1} = P_{N+1} (\Phi_{N+1}^T W_{N+1} Y_{N+1})$$

$$= P_{N+1} \left(\begin{bmatrix} \Phi_N \\ \phi_{N+1}^T \end{bmatrix}^T \begin{bmatrix} P \cdot W_N & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} Y_N \\ y_{(n+N+1)} \end{bmatrix} \right)$$

$$= P_{N+1} [P \Phi_N^T W_N Y_N + \phi_{N+1} y_{(n+N+1)}]$$

$$= P_{N+1} [P P_N^{-1} \hat{\theta}_N + \phi_{N+1} y_{(n+N+1)}]$$

$$= P_{N+1} [(P_{N+1}^{-1} - \phi_{N+1} \phi_{N+1}^T) \hat{\theta}_N + \phi_{N+1} y_{(n+N+1)}]$$

$$= \hat{\theta}_N + P_{N+1} \phi_{N+1} [y_{(n+N+1)} - \phi_{N+1}^T \hat{\theta}_N] \rightarrow \text{新息}$$

$$= \hat{\theta}_N + \frac{1}{P} \left(P_N - \frac{P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + P} \right) \cdot \phi_{N+1} [y_{(n+N+1)} - \phi_{N+1}^T \hat{\theta}_N]$$

$$= \hat{\theta}_N + \frac{1}{P} \cdot \frac{P_N \phi_{N+1}^T P_N \phi_{N+1} + P_N \cdot P - P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + P} \cdot \phi_{N+1} [y_{(n+N+1)} - \phi_{N+1}^T \hat{\theta}_N]$$

标量, 位置可以随高放

$$= \hat{\theta}_N + \frac{1}{P} \frac{P_N \phi_{N+1}^T P_N \phi_{N+1} + P_N \cdot P - P_N \phi_{N+1} \phi_{N+1}^T P_N}{\phi_{N+1}^T P_N \phi_{N+1} + P} [y_{(n+N+1)} - \phi_{N+1}^T \hat{\theta}_N]$$

$$= \hat{\theta}_N + \frac{P_N \phi_{N+1}}{\phi_{N+1}^T P_N \phi_{N+1} + P} [y_{(n+N+1)} - \phi_{N+1}^T \hat{\theta}_N]$$

如果分子是0, 乘以小于1的数

越新的数据, 加权越大, 越重视, 即 P_N^{-1} 越大, P_N^{-1} 越小, 权重越小

3. 有限记忆法 (剔除) —— 可看成删消记忆法的特例: $\rho=0$ 或 $\rho=1$

$k=1, 2, \dots, N \rightarrow$ 固定窗口法

$$\theta = (\Phi_N^T \Phi_N)^{-1} (\Phi_N^T Y_N) \quad \theta_N \text{ 在不停变化, 每增加一个数据, 去掉一个}$$

$$\Phi_N^T \Phi_N \theta = \Phi_N^T Y_N \quad (*) \quad \text{老数据, } P_N \text{ 在变化}$$

$$\Phi_N = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix} \quad Y_N = \begin{bmatrix} y_{(n+1)} \\ y_{(n+2)} \\ \vdots \\ y_{(n+N)} \end{bmatrix} \quad \hat{\theta}_N \text{ 在变化}$$

考试要求自己会写 Φ_N, Y_N 等

$$\Phi_{N+1} = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \\ \phi_{N+1}^T \end{bmatrix} \quad Y_{N+1} = \begin{bmatrix} y_{(n+1)} \\ y_{(n+2)} \\ \vdots \\ y_{(n+N)} \\ y_{(n+N+1)} \end{bmatrix} \quad (k=N+1)$$

$$\hat{\theta}_{N+1} = (\Phi_{N+1}^T \Phi_{N+1})^{-1}$$

$$\text{协方差矩阵} = \left(\sum_{k=1}^N \phi_k \phi_k^T \right)^{-1}$$

$$= \left(\sum_{k=1}^N \phi_k \phi_k^T + \phi_{N+1} \phi_{N+1}^T - \phi_1 \phi_1^T \right)^{-1}$$

$$= (P_N^{-1} + \phi_{N+1} \phi_{N+1}^T - \phi_1 \phi_1^T)^{-1}$$

P_{N+1} : 表示 $(N+1)$ 时刻对 θ 估计的协方差, 即 $\hat{\theta}$

$$\text{令 } (P_N^{-1} + \phi_{NH} \phi_{NH}^T)^{-1} = W_{NH} \quad \text{矩阵求逆公式:}$$

$$\Rightarrow W_{NH} = P_N^{-1} - \frac{P_N^{-1} \phi_{NH} \phi_{NH}^T P_N^{-1}}{\phi_{NH}^T P_N^{-1} \phi_{NH} + 1} \quad (A + HBH^T)^{-1} = A^{-1} - A^{-1}H(H^T A^{-1}H + B^{-1})^{-1}H^T A^{-1}$$

$$\text{则 } P_{N+1} = (W_{NH}^{-1} - \phi_1 \phi_1^T)^{-1}$$

$$= W_{NH} - \frac{W_{NH} \phi_1 \phi_1^T W_{NH}}{\phi_1^T W_{NH} \phi_1 + 1}$$

$$= P_N - \frac{P_N \phi_{NH} \phi_{NH}^T P_N}{\phi_{NH}^T P_N \phi_{NH} + 1} - \frac{W_{NH} \phi_1 \phi_1^T W_{NH}}{\phi_1^T W_{NH} \phi_1 + 1}$$

对于(*)式:

$$(\sum_{k=1}^{NH} \phi_k \phi_k^T) \theta_{NH} = \sum_{k=1}^{NH} \phi_k y(n+k)$$

$$\text{即: } (P_N^{-1} + \phi_{NH} \phi_{NH}^T - \phi_1 \phi_1^T) \theta_{NH} = \sum_{k=1}^{NH} \phi_k y(n+k) + \phi_{NH} y(n+NH+1) - \phi_1 y(n+1) \quad (**)$$

$$\text{则: } (P_N^{-1} + \phi_{NH} \phi_{NH}^T - \phi_1 \phi_1^T) \theta_N = P_N^{-1} \theta_N + \phi_{NH} \phi_{NH}^T \theta_N - \phi_1 \phi_1^T \theta_N$$

$$= \phi_N^T \gamma_N + \phi_{NH} \phi_{NH}^T \theta_N - \phi_1 \phi_1^T \theta_N \quad (***)$$

(**)式 - (***)式得:

$$(P_N^{-1} + \phi_{NH} \phi_{NH}^T - \phi_1 \phi_1^T) (\theta_{NH} - \theta_N)$$

$$= \phi_{NH} [y(n+NH+1) - \phi_{NH}^T \theta_N] - \phi_1 [y(n+1) - \phi_1^T \theta_N]$$

新息 $\hookrightarrow \hat{y}(n+NH+1/n+NH)$ $\hookrightarrow \hat{y}(n+1/n+1)$ - 对数据的平滑

$$\therefore \theta_{NH} = \theta_N + (P_N^{-1} + \phi_{NH} \phi_{NH}^T - \phi_1 \phi_1^T)^{-1} \{ \phi_{NH} [y(n+NH+1) - \phi_{NH}^T \theta_N] - \phi_1 [y(n+1) - \phi_1^T \theta_N] \}$$

3. 遗忘因子

越大: 遗忘的越快

变化慢, 老数据占比重大, 遗忘因子应该取大一些;

$$\rho^{N-k} \quad (0 < \rho < 1)$$

变化剧烈, 老数据占比重小, 遗忘因子应该取小一些。

① 问题的提出

参数变化的速度并非一成不变的, 有时变化快, 有时变化慢; 希望变化缓慢时, 老数据对本时刻的估计影响大, 应该让它占的比重大一点, 当变化剧烈时, 应该让老数据占的比重小一点。

剧烈: $\rho \rightarrow$ 小 缓慢: $\rho \rightarrow$ 大

② 考虑 $y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i)$

定义 $\phi_N^T \phi_N$ 为信息矩阵 Information Matrix

课本: 由于矩阵 ϕ_N 是由 $(n+N)$ 次采样得到的所有输入、输出数据构成的, 所以它包含了系统的动态信息, 因此称 $\phi_N^T \phi_N$ 为信息矩阵, 其信息量为先验误差的加权平方和, 记为 Σ , 并有如下递推公式:

$$\Sigma_{NH} = P_{NH} \cdot \Sigma_N + (1 - \phi_{NH}^T K_{NH}) I_{NH}^2 \quad \text{--- 此公式不用记}$$

$$\text{其中, } K_{NH} = \frac{P_{NH} \phi_{NH}}{\phi_{NH}^T P_{NH} \phi_{NH} + 1}$$

$$\text{预测误差 } I_{NH} = y(n+NH+1) - \phi_{NH}^T \hat{\theta}_N$$

问题: $k=N+1$ 时刻, 如何确定遗忘因子 ρ_{NH} ?

选择遗忘因子 ρ 的目标是使信息矩阵的信息保持不变, 即让每一时刻参与辨识的量相等:

$$\Sigma_{NH} = \Sigma_N = \dots = \Sigma_1 \quad \text{总信息量不变}$$

上-时刻的信息量 当前时刻的信息量

注意: 此处若都将 $=$ 换成 $>$ 号, 则信息量会越来越大, 就会得出 $\rho_{NH} > 1$ 的结论。

即数据越来越重要, 得出了矛盾的结论, 是不允许的。

15 也就是说, 在每一步丢掉的信息量相当于最近一次量测中得到的新信息量, 总信息量保持不变。

0.01 得分

基于上述思想, 取遗忘因子 ρ_{NH} , 使得满足:

$$\sum_{NH} = \underbrace{\rho_{NH} \cdot \sum_N}_{\text{新息}} + \underbrace{(1 - \phi_{NH}^T K_{NH}) I_{NH}}_{\text{输出 } p_{N+1}} = \sum_N$$

即取
$$\rho_{NH} = 1 - \frac{(1 - \phi_{NH}^T K_{NH}) I_{NH}}{\sum_N}$$

其中, $1 - \phi_{NH}^T K_{NH} = 1 - \frac{\phi_{NH}^T P_N \phi_{NH}}{\phi_{NH}^T P_N \phi_{NH} + 1} = \frac{1}{\phi_{NH}^T P_N \phi_{NH} + 1}$ 正定

2017年11月23日

Date: / /

问: 递推最小二乘与卡尔曼滤波的区别与联系?

递推最小二乘是卡尔曼滤波的一个特例, 它们都是最小二乘意义下的, 针对线性、离散系统的;

最小二乘法: 定常系统的参数估计问题.

渐消记忆法: 时变系统

限定记忆法: 一种特殊的渐消或递推最小二乘, 只不过 ρ 不是渐变的, 而只取 0 或 1, 保持参与辨识的数据的规模不变.

遗忘因子: 适用于变化忽快忽慢的时变系统.

第四章 相关(有色)噪声情形下的参数辨识

白色噪声是独立的.

§4.1 引言

考虑 $y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + \varepsilon(n+k)$

第三章中, 构造目标函数 $J(\theta) = \sum_{k=1}^N \varepsilon^2(n+k) \rightarrow \min \Rightarrow \hat{\theta}$

参量 θ 的最小二乘估计为 $\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N$

$$Y_N = \Phi_N \theta + \varepsilon_N$$

$$\varepsilon_N \triangleq [\varepsilon(n+1) \dots \varepsilon(n+N)]^T$$

$$\Phi_N = \begin{bmatrix} -y(n+k-1) & \dots & -y(k), u(n+k-1) & \dots & u(k) \end{bmatrix}$$



和 $\varepsilon(n+k-1)$ 有关



和 $\varepsilon(k)$ 有关

$$\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} (\Phi_N^T Y_N)$$

$$= (\Phi_N^T \Phi_N)^{-1} \Phi_N^T (\Phi_N \theta + \varepsilon_N)$$

$$\begin{aligned}
 &= \theta + (\Phi_N^T \Phi_N)^{-1} \Phi_N^T \varepsilon_N \\
 &= \theta + \left(\sum_{k=1}^N \phi_k \phi_k^T \right)^{-1} \left(\sum_{k=1}^N \phi_k \varepsilon(n+k) \right) \\
 &= \theta + \left(\frac{1}{N} \sum_{k=1}^N \phi_k \phi_k^T \right)^{-1} \left(\frac{1}{N} \sum_{k=1}^N \phi_k \varepsilon(n+k) \right)
 \end{aligned}$$

当 $\varepsilon(n+k)=0$, 即 $\varepsilon(k)$ 为零均值, 不相关序列时, 由于 ϕ_k 只与 $\varepsilon(n+k-1), \dots, \varepsilon(k)$ 相关, 与 $\varepsilon(n+k)$ 无关, 所以 $\hat{\theta} = \theta$.

当 $\varepsilon(n+k) \neq 0$ 时,

若 $u(k), \varepsilon(k)$ 是平稳, 遍历的, 则有:

$$\begin{cases}
 \frac{1}{N} \sum \phi_k \phi_k^T \xrightarrow{P} E(\phi_k \phi_k^T) \geq 0 \\
 \frac{1}{N} \sum \phi_k \varepsilon(n+k) \xrightarrow{P} E(\phi_k \varepsilon(n+k))
 \end{cases}$$

$\Rightarrow$ 一个样本在某时刻的特性可能等于很长时间的统计特性.

说明: $a \xrightarrow{P} b$, 表示 a 以概率收敛到 b .

$E(\cdot)$, 表示 $(\cdot)$ 的数学期望.

总结:

若 $\varepsilon(n+k)$ 为零均值的白噪声, ϕ_k 和 $\varepsilon(n+k)$ 无关, 可分别求均值, 则 $\hat{\theta} \xrightarrow{P} \theta$.

若 $\varepsilon(n+k)$ 为有色噪声, 则 $\hat{\theta} \not\xrightarrow{P} \theta$.

$\Rightarrow$ 当噪声序列相关时, 最小二乘估计最优但不能保证收敛.

由于有色噪声的存在, $\hat{\theta}$ 不能以概率 P 收敛于 θ .

§4.2 辅助变量法 为了解决这个不收敛的问题

1. 思路

L.S.E (最小二乘意义下的)

$$\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} (\Phi_N^T Y_N) = \theta + \left(\frac{1}{N} \Phi_N^T \Phi_N \right)^{-1} \left(\frac{1}{N} \Phi_N^T \varepsilon_N \right) \quad (1)$$

$\hat{\theta}$ 不收敛的根源是: ϕ_k 与 $\varepsilon(n+k)$ 相关.

$$\text{估计 } \hat{y} \rightarrow \hat{\phi}_k \rightarrow \hat{\Phi}_N$$

拿 $\hat{\Phi}_N$ 代替上式中的 Φ_N

$$\hat{\theta} = (\hat{\Phi}_N^T \hat{\Phi}_N)^{-1} \hat{\Phi}_N^T Y_N$$

$$\text{则 } \hat{\theta} = \theta + \left(\frac{1}{N} \hat{\Phi}_N^T \hat{\Phi}_N \right)^{-1} \left(\frac{1}{N} \hat{\Phi}_N^T \varepsilon_N \right) \rightarrow \theta$$

因为 $\hat{\Phi}_N$ 已经最优, 但不收敛. 想改不收敛至收敛, 且改动很小, 所以拿 $\hat{\Phi}_N^T$ 代替 Φ_N^T , 而 Φ_N 不变. 实际上, Φ_N 可变可不变. $\hat{\Phi}_N$ 对最终收敛结果影响不大. $\hat{\Phi}_N$ 称为辅助变量, 不唯一.

问题: 怎么计算 $\hat{\Phi}_N$?

2. 辅助变量法的实现

利用 $\{y(k), u(k)\}$

$$\text{考虑 } y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + \varepsilon(n+k)$$

$$(1) \text{ 令 } y(n+k) = -\sum \bar{a}_i y(n+k-i) + \sum \bar{b}_i u(n+k-i) + \varepsilon(n+k) \quad \text{利用前 } n \text{ 个数据}$$

$$\bar{\theta} = [\bar{a}_1, \bar{a}_2, \dots, \bar{a}_n, \bar{b}_1, \bar{b}_2, \dots, \bar{b}_n]^T \quad \text{最终要求的 } \theta, \text{ 相当于前}$$

$$\text{L.S.E } \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N \xrightarrow{P} \theta$$

不收敛到 θ

然后用到 $n+k$ 次的 $\hat{\Phi}_N$ 中

$$(2) \hat{y}(n+k) = -\sum \hat{a}_i \hat{y}(n+k-i) + \sum \hat{b}_i u(n+k-i) \quad \text{根据一组已知数据估计出来的}$$

$$(3) \hat{\phi}_k = [-\hat{y}(n+k-1), \dots, -\hat{y}(k), u(n+k-1), \dots, u(k)]^T$$

$$\Phi_k = [-y(n+k-1), \dots, -y(k), u(n+k-1), \dots, u(k)]^T$$

$$\hat{\Phi}_N = \begin{bmatrix} \hat{\phi}_1^T \\ \hat{\phi}_2^T \\ \vdots \\ \hat{\phi}_N^T \end{bmatrix} \quad \Phi_N = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix}$$

$$(4) \hat{\theta} = (\hat{\Phi}_N^T \Phi_N)^{-1} \hat{\Phi}_N^T Y_N \xrightarrow{P} \theta$$

0.001

§ 状态的推广：将不可测的估计出来

模型的降阶（降维）

辅助变量法思路总结：

因为测量的 y 都相互相关，所以不用测量的 y ，而是估计出一系列的 $\hat{y}$ 。 $\hat{y}$ 和 e 不相关，然后用 $\hat{y}$ 代替 y 。（估计 $\hat{y}$ 时的一系列初值可随意选，因为它对初值不敏感。）

§ 4.3 推广最小二乘估计

$$y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + e(n+k)$$

$$e(k) = e(k) + c_1 e(k-1) + \dots + c_m e(k-m)$$

[任意一个相关噪声都可以用白噪声的线性组合序列来表示，区别在于阶次，由多少白噪声表示]

$$y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + \sum e(n+k-i)$$

$$\text{令 } \bar{\theta} = [a_1, \dots, a_n, b_1, \dots, b_n, c_1, \dots, c_m]^T$$

$$\phi_k = [-y(n+k-1), \dots, -y(k), u(n+k-1), \dots, u(k), e(n+k-1), \dots, e(k)]^T$$

$$y(n+k) = \phi_k^T \bar{\theta} + e(n+k)$$

$$\Rightarrow \hat{\bar{\theta}} = (\bar{\Phi}_N^T \bar{\Phi}_N)^{-1} \bar{\Phi}_N^T Y_N$$

$$\hat{e}(n+k) = y(n+k) + \sum a_i y(n+k-i) - \sum b_i u(n+k-i) - \sum c_i e(n+k-i)$$

$$\hat{\phi}_k = [y, u, \hat{e}]^T$$

§ 4.4 闭环系统的辨识

1. 问题的提出

① 稳定性判断方法 § 劳斯判据，特征根

频域：奈奎斯特判据

闭环系统比开环系统稳定性好很多，闭环系统的输入、输出数据所提供的信息比开环的少，不易辨识。

② 输入 $u(k) = \begin{cases} u(k) & \text{— 状态反馈} \\ u(y) & \text{— 输出反馈} \end{cases}$

例 4.1 考虑 $y(k+1) = -ay(k) + bu(k) + e(k+1)$ 开环-阶系统

↓ 估计 ↓

§ u 是给定的：开环

若 $u(k) = \lambda y(k)$ (λ 已知)

§ u 和 y 有关，由 y 代入的：闭环

则 $y(k+1) = -ay(k) + b\lambda y(k) + e(k+1)$ 闭环系统

阶次： $k+1=k=1$ 阶

$$y(k+1) = (-a + b\lambda)y(k) + e(k+1)$$

$$y(k+1) = -\bar{\lambda}y(k) + e(k+1)$$

$$\bar{\lambda} = a + b\lambda \quad \bar{\lambda} \text{ 是可辨识的}$$

$$\left. \begin{matrix} \bar{\lambda} \\ \lambda \end{matrix} \right\} \Rightarrow \begin{cases} a \\ b \end{cases} \quad \text{即：已知 } \bar{\lambda} \text{ 和 } \lambda, a \text{ 和 } b \text{ 不能唯一确定。}$$

2. 闭环系统的可辨识性 § 结构可辨识性 — 先验

参数可辨识性 — 后验

若数据量足够多，无噪声扰动，仍不能辨识出系统参数 a, b — 结构不可辨识

参数辨识与数据量（信息量），噪声扰动有关。

§ 辨识：开环好辨识，闭环不好辨识 $\Rightarrow$ § 有利于辨识的不利于控制
控制：闭环好控制，开环不好控制 有利于控制的不利于辨识

3. 闭环系统可辨识的充分条件

① 反馈控制器的阶次大于等于系统前向通道的阶次。

$$u(k) = \lambda_1 y(k) + \lambda_2 y(k-1) \quad \lambda_1, \lambda_2 \text{ 已知}$$

$$\begin{aligned} \text{闭环: } y(k+1) &= -ay(k) + b\lambda_1 y(k) + b\lambda_2 y(k-1) + e(n+k) \\ &= (-a + b\lambda_1)y(k) + b\lambda_2 y(k-1) + e(n+k) \end{aligned}$$

$$= \bar{\lambda}_1 y(k) + \bar{\lambda}_2 y(k-1) + e(n+k)$$

$$\begin{cases} \bar{\lambda}_1 = -a + b\lambda_1 \\ \bar{\lambda}_2 = b\lambda_2 \end{cases} \xrightarrow{\lambda_1 \rightarrow a \quad \checkmark} \text{在提高了阶次后, 可辨识了.}$$

② 多个控制器相互切换

$$\begin{cases} u(k) = \lambda_1 y(k) & \lambda_1, \lambda_2 \\ u(k) = \lambda_2 y(k) & \lambda_1 \neq \lambda_2 \end{cases}$$

$$\text{闭环系统: } \begin{cases} y(k+1) = -\bar{\lambda}_1 y(k) + e(k+1) \\ y(k+1) = -\bar{\lambda}_2 y(k) + e(k+1) \end{cases}$$

$$\begin{cases} \bar{\lambda}_1 \rightarrow -a \quad \checkmark & \text{可辨识} \\ \bar{\lambda}_2 \rightarrow -b \quad \checkmark & \text{对辨识有利的对控制不利} \end{cases}$$


平滑控制器, 切换会引起很大的震荡.

切换会造成系统不稳定, 状态不稳定, 不能瞬间完成, 对控制系统应尽量减少控制器切换.

4. 常用的辨识模型实现方法

① 直接法

在前向通道测取输出 (而不需闭环如何控制的), 通过开环反推闭环辨识, 要求前向通道可测.



② 间接法

在闭环的情况下, 测取输出输入, 进行辨识.

2017年11月30日

Date: / /

问: 开环和闭环系统哪个更容易辨识?

输出和输入的紧密相关性, 强行让输出和输入相等, 信息量变, 故开环更利于辨识.

书: 闭环系统是稳定的, 对于反馈产生的不同输入可能获得几乎相同的输出. 因此, 闭环系统的输入, 输出数据所提供的信息比开环少, 加大了辨识的难度.

2. 举出两种提高系统可辨识的方法? (而且输入不再与输出及其所受干扰独立, 而与输出噪声相关)

① 提高系统阶次 ② 多个控制器切换

3. 上述两种方案带来的不利影响?


① 阶次越高, 干扰被放大倍数越大, 实际阶次一般不会太高, 噪声问题存在. 阶次高本身就是一种放大噪声.

② 有切换的时间问题, 时效性差. (切换时, 下个控制器的控制作用依据上个控制器的切换时刻的值, 并非当前值.)

§ 4.5 闭环最小二乘辨识

考虑单输入单输出系统, 其正向通道数学模型为:

$$y(k) = -\sum_{i=1}^{n_a} a_i y(k-i) + \sum_{j=0}^{n_b} b_j u(k-j) + e(k)$$



反馈控制器模型为:

$$u(k) = -\sum_{i=1}^{n_d} d_i u(k-i) + \sum_{j=0}^{n_c} c_j y(k-j) + e(k)$$

其中 d_j, c_j 已知

$\{e(k)\}, \{e(k)\}$ 为独立的零均值高斯白噪声.

令 $\theta = [a_1, \dots, a_{n_a}, b_1, \dots, b_{n_b}]^T \in \mathbb{R}^{n_a+n_b}$

$$\phi_k = [-y(k-1), \dots, -y(k-n_a), u(k-1), \dots, u(k-n_b)]^T$$

$\downarrow$ $\downarrow$ $\downarrow$ $\downarrow$
 $\varepsilon(k-1)$ $\dots$ $\varepsilon(k-n_a)$ $y(k-1-p)$ $\dots$ $y(k-1-n_b)$ $y(k-n_b-p)$ $\dots$ $y(k-n_b-n_c)$
 和 $\varepsilon(k)$ 前有关 $\varepsilon(k-1-p) \dots \varepsilon(k-1-n_c)$ $\varepsilon(k-n_b-p) \dots \varepsilon(k-n_b-n_c)$

则 $y(k) = \phi_k^T \theta + \varepsilon(k)$

再令 $\Phi_N = \begin{bmatrix} \phi_{n+1}^T \\ \phi_{n+2}^T \\ \vdots \\ \phi_{n+N}^T \end{bmatrix}$ $Y_N = \begin{bmatrix} y(n+1) \\ y(n+2) \\ \vdots \\ y(n+N) \end{bmatrix}$ $E_N = \begin{bmatrix} \varepsilon(n+1) \\ \varepsilon(n+2) \\ \vdots \\ \varepsilon(n+N) \end{bmatrix}$

$n = \max\{n_a, n_b\}$

则 $Y_N = \Phi_N \theta + E_N$

当 $E(k) \neq 0$ 时, Φ_N 可逆

$$\hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T (\Phi_N \theta + E_N)$$

$$= \theta + (\Phi_N^T \Phi_N)^{-1} \Phi_N^T E_N = \theta + \left(\sum_{k=n+1}^{n+N} \phi_k \phi_k^T \right)^{-1} \left(\sum_{k=n+1}^{n+N} \phi_k \varepsilon(k) \right)$$

$P \xrightarrow{L} E(\phi_k, \phi_k^T)$ $P \xrightarrow{L} E(\phi_k, \varepsilon(k))$

当 $\varepsilon(k) = 0$ 时, 则 $\hat{\theta} = \theta$

当 $\varepsilon(k) \neq 0$ 时 $\begin{cases} \sum_{k=n+1}^{n+N} \phi_k \phi_k^T \xrightarrow{P} E(\phi_k, \phi_k^T) \\ \sum_{k=n+1}^{n+N} \phi_k \varepsilon(k) \xrightarrow{P} E(\phi_k, \varepsilon(k)) \end{cases}$

当 $p+q > 0$ 时, $E(\phi_k) E(\varepsilon(k)) \rightarrow 0$ $\hat{\theta}_N \xrightarrow{P} \theta$

此时, 若 $p=1$ 时, $u(k)$ 至少为一阶系统, 用微分控制器, 若 $n_c > 1$ 为 n_c 阶控制器。

当 $E(k) = 0$ 时, Φ_N 不可逆

问: 怎么判断一个系统是否可以辨识?

闭环系统可辨识的充分条件: 反馈通道阶次 $>$ 前向通道阶次

前向通道阶次: n_a 阶 $\Rightarrow$ 前向通道中反馈被延迟的节拍: $k-1, \dots, k-n_b$

$\Rightarrow$ 进入反馈控制器被延迟的节拍: $k-n_c-1$

反馈控制器的阶次大于前向通道阶次, 参数 θ 可辨识, 即: $n_c + 1 > n_a$

第五章 线性动态模型系统的辨识

§ 5.1 引言

考虑: $y(n+k) = -\sum_{i=1}^n a_i y(n+k-i) + \sum_{i=1}^n b_i u(n+k-i) + e(n+k)$

$\theta = [a_1, \dots, a_n, b_1, \dots, b_n]^T \in \mathbb{R}^{2n}$

如何在不知道阶次 n 的情况下辨识出 n 、 a 和 b ?

§ 5.2 阶的辨识方法

1. 损失函数法 (Loss function)


在最小二乘意义下 (L.S.E),

$J(n, \theta) = \sum_{k=1}^N e^2(n+k) \Rightarrow$ 希望真实量测输出与模型计算输出误差最小。

$(\hat{n}, \hat{\theta}) = \arg \min J(n, \theta)$ 意义: 当 $J(n, \theta)$ 取最小值时, 对应 $\hat{n}$ 和 $\hat{\theta}$ 的取值。

$n=1, 2, \dots$ (每给定一个 n , 就算出它的目标函数)

由 $\hat{n} \Rightarrow \hat{\theta} = (\Phi_N^T \Phi_N)^{-1} \Phi_N^T Y_N \Rightarrow J(\hat{n}, \hat{\theta})$



2. F-检验法

此时刻到下一时刻变化比较小

背景(书): 实际问题中, 很难给出一个相差多大才算有显著差异的一般标准。因此, 单从损失

函数的绝对值很难判定它们之间是否有显著差异, 通常需借助于统计检验方法。

delian

①思路: 假设 $n_1 < n_2$ (一般情况下 $n_2 = n_1 + 1$)

若 $J(n_1) \gg J(n_2)$ n_2 更接近于系统的阶次

$J(n_1) \approx J(n_2)$ n_1 更接近于系统的阶次

$$\text{构造统计量: } \bar{F} = \frac{J(n_1) - J(n_2)}{J(n_2)} \cdot \frac{N - 2n_2}{2(n_2 - n_1)}$$

其中 N 为样本数, $J(\cdot)$ 为损失函数, $\bar{F}$ 表征是否有显著差异.

定理 5.1 (K. J. Astrom)

假设 $\{e(n)\}$ 为高斯白噪声, 当 $n_2 \gg n_1 \geq n_0$ 时, (n_0 为系统真实的阶), $J(n_1)$ 和 $J(n_2) - J(n_1)$ 也是独立的随机变量. 当 N 充分大时, $\bar{F}$ 渐近服从 $F[2(n_2 - n_1), N - 2n_2]$


举例说明 (续前):

$$x_i \approx N(0, 1) \quad i=1, 2, \dots, n$$

$$\sum_{i=1}^n x_i^2 \sim \chi^2(n)$$

$$u, v, \quad u \sim \chi^2(n_1), \quad v \sim \chi^2(n_2)$$

$$W = \frac{u}{v} \cdot \frac{n_2}{n_1} \sim F(n_1, n_2) \Rightarrow F_\alpha$$



$$\alpha = 0.02$$

$$P(F \geq F_\alpha) = \alpha$$

利用统计量 $\bar{F}$ 来检验 $H_0: n_0 \geq n_1 \geq n_2$

①给定 $n_2 \gg n_1$, 用最小二乘法求出 $\hat{\theta}$ 代入目标函数求出 $J(n_1), J(n_2)$, 算出 $\bar{F}$. $\hat{\theta} = (\phi^T(n_2) \phi(n_2))^{-1} \phi^T(n_2) y$

②根据给定 α , 查表得 F_α , 与 $\bar{F}$ 比较. (α —置信度)

若 $\bar{F} < F_\alpha$ 时, 接受 H_0 , 说明 $J(n_1)$ 与 $J(n_2)$ 不显著差异, 即 n_1 可确定为系统的阶;

若 $\bar{F} \geq F_\alpha$ 时, 拒绝 H_0 , 说明 $J(n_1)$ 与 $J(n_2)$ 有显著差异, 即 n_2 更接近于真实阶.

(当 n_2 和 n_1 都位于 n_0 右侧时, 才服从 F 分布.)

举例: $n_1 = 1, 2, \dots, n_2 = n_1 + 1$ $n_1 \rightarrow$ 大 (n_1 逐渐增大):

$$n_2 = n_1 + 1$$

每增加一次就进行一次 F 检验:

$$F \geq F_\alpha$$

$$P_{n+1} = P_n^{-1} + \phi(n+1) \phi(n+1)^T$$

$$P_{n+1} = P_n - \frac{P_n \phi(n+1) \phi(n+1)^T P_n}{\phi(n+1)^T P_n \phi(n+1) + 1}$$

$$\exists \hat{n}, \text{使得 } \begin{cases} n_1 = \hat{n} & \bar{F}(\hat{n}) \geq F_\alpha \\ n_2 = n_1 + 1 \end{cases}$$

此时说明拐点出现了.

$$\begin{cases} n_1 = \hat{n} + 1 & \bar{F}(\hat{n}) < F_\alpha \\ n_2 = n_1 + 1 \end{cases}$$

此时, 系统的阶次为 $\hat{n} + 1$.

3. 赤池信息准则法 (Akaike Information Criterion - AIC)

赤池弘次

$$AIC(p) = -2 \log L(Y, U, \theta) + 2p$$

表示模型的准确性

表示模型的复杂性

U/Y — 系统输入/输出数据

L — 系统的似然函数 $\in [0, 1]$

p — 自由参数 (可独立调整) 的数目

θ — 未知参数, 需要我们估计

$$\text{考虑: } y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + e(n+k)$$

$$p = 2n, \quad \alpha = n$$

$$\text{给定 } n_1, n_2 \quad \text{则 } p_1 = 2n_1, \quad p_2 = 2n_2$$

假设有两个模型:

$$S_1: \text{精度很低, 不准} \rightarrow L(Y, U, \theta) \rightarrow 0 \Rightarrow \log \rightarrow -\infty \Rightarrow AIC(p_1) \rightarrow +\infty$$

$$S_2: \text{精度很高, 精准} \rightarrow L(Y, U, \theta) \rightarrow 1 \Rightarrow \log \rightarrow 0 \Rightarrow AIC(p_2) \rightarrow 2p_2 \ll AIC(p_1)$$

AIC 值最小的模型最好.

若 $e(n)$ 为线性高斯分布时, L 退化为最小二乘, θ 变成最小二乘估计了 (极大似然和最小二乘一致)

若两个模型都很准, 则阶次低 (p 值小) 的模型好.

$$S_1: \checkmark \quad L(Y, U, \theta) \rightarrow 1 \Rightarrow \log \rightarrow 0 \Rightarrow \text{若 } p_1 < p_2, \text{ 则 } AIC_1 \text{ 小, 模型 } S_1 \text{ 好.}$$

$$S_2: \checkmark \quad L(Y, U, \theta) \rightarrow 1 \Rightarrow \log \rightarrow 0$$

AIC(n)

AIC(p)

阶数

n_0

(p_0)

n/p

一次函数

当 $n \leq n_0$ 时, 第一项起主导, 则前半段为 $\log$ 曲线.

当 $n > n_0$ 时, 第二项起主导, 则后半段为直线.

4. 行列式法

考虑: $y(n+k) = -\sum a_i y(n+k-i) + \sum b_i u(n+k-i) + e(n+k) = \phi_k^T \theta + e(n+k)$

$$\phi_k = [-y(n+k-1) \dots -y(n), u(n+k-1) \dots u(n)]^T$$

$$\theta = [a_1, \dots, a_n, b_1, \dots, b_n]^T$$

$$\Phi_N = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix} = \begin{bmatrix} -y(n) \dots -y(1) & u(n) \dots u(1) \\ -y(n+1) \dots -y(2) & u(n+1) \dots u(2) \\ \vdots & \vdots \\ -y(n+N-1) \dots -y(N) & u(n+N-1) \dots u(N) \end{bmatrix}$$

$$Y_N = [y(n) \dots y(n+N)]^T$$

$$Y_N = [y(n) \dots y(n+N)]^T$$

$$Y_N = -Y(n+1) = \Phi_N \theta + e_N = [Y(n) \dots Y(n), u(n) \dots u(n)] \theta + e_N$$

$$= a_1 Y(n) + \dots + a_n Y(1) + b_1 u(n) + \dots + b_n u(1) + e_N$$

$$= a_n Y(n) + b_n u(n) + \dots + a_1 Y(n) + b_1 u(n) + e_N$$

$$= [Y(n), u(n), Y(n), u(n)]^T [a_n, b_n, a_{n-1}, b_{n-1}, \dots, a_1, b_1]^T + e_N$$

$$\triangleq \bar{\Phi}_N \bar{\theta} + e_N$$

令 $\bar{\Phi}(p, q)$ 表示 $Y(n)$ 和 $u(n)$ 按时间顺序排列得到的矩阵, 其中包含 p 列的 $Y(n)$ 和 q 列的 $u(n)$.

$$p \geq q (p=q \text{ or } p=q+1)$$

$$p=1, q=0 \text{ 时, } \bar{\Phi}(p, q) = \bar{\Phi}(1, 0) = [Y(n)]$$

$$p=1, q=1 \text{ 时, } \bar{\Phi}(p, q) = \bar{\Phi}(1, 1) = [Y(n), u(n)]$$

$$p=10, q=9 \text{ 时, } \bar{\Phi}(p, q) = \bar{\Phi}(10, 9) = [Y(n), u(n), \dots, Y(9), u(9), Y(10)]$$

$$\text{令 } S(p, q) = \bar{\Phi}^T(p, q) \bar{\Phi}(p, q)$$

若 $e_N \approx 0$, 模型阶次为 n , 则 $\bar{\Phi}(n, n)$ 满秩, $\bar{\Phi}(n+1, n)$ 降秩.

$$\frac{\det S(p, q)}{\det S(n, n)} < \varepsilon \quad \text{此时模型的阶为 } n.$$

2017年12月7日

Date: / /

上节中讲到的四种线性系统模型阶的辨识方法, 都是通过评价策略来确定阶次, 而不是计算是通过对阶次不断提高, 一个去试, 不断地逼近系统真实的阶次.

都不是采用具体的阈值来划分阶次.

F-检验法和AIC准则都是损失函数法的具体体现, 用了不同的统计方法.

第六章 结构已知的非线性系统的参数辨识

线性和非线性最基本的区别: 是否满足叠加原理.

很多情况下, 线性系统的输入输出可以解耦或部分解耦, 非线性系统很难解耦.

线性系统: 解决标准型问题, 将五花八门的形式表示成标准形式.


非线性系统具有的, 线性系统所没有的现象: (书) 跳跃, 滞回, 极限环, 分岔及混沌运动

① 非线性系统对初值, 参数和扰动都异常敏感, 线性系统不太敏感.

注: 非线性系统也具有能控, 能观性, 只不过没有具体指标, 比较复杂.

② 非线性系统的稳定域很小, 线性系统换个参数稳定域可能会很大, 而非线性系统不行.

③ 非线性系统具有多平衡点, 有多解. (非线性系统的解分叉).



§ 6.2 迭代算法 (梯度下降 Gradient descent)

考虑 $y = f(u, \theta)$ f 已知, θ 未知

$$\{u(k), y(k) \quad k=1, 2, \dots, N\}$$

$e(k) \triangleq y(k) - f(u(k), \theta)$ 真实输出与模型输出的偏差

$$J(\theta) = \sum_{k=1}^N e^2(k) \quad (\text{or } \sum_{k=1}^N e^T(k) e(k))$$

$\theta^* = \arg \min J(\theta)$ 线性系统: $y(k) = \phi^T \theta$ $e(k) \sim \theta$

$$\frac{\partial J}{\partial \theta} = 0 \quad f(\theta) = 0 \Rightarrow \theta \text{ 解不出来}$$

$$J = e^2$$

(多平衡点, 存在多解问题)

$$\frac{\partial J}{\partial \theta} = 0 \Rightarrow \theta \text{ 可求出 } \theta \text{ 的封闭解}$$

2. 思路

从某一初始猜测值 $\theta^{(0)}$ 出发: $\theta^{(0)} \xrightarrow{\Delta \theta} \theta^{(1)} \xrightarrow{\Delta \theta} \theta^{(2)} \dots \rightarrow \theta^{(n)}$ $\theta^{(n)}$ 进行变化

$$J(\theta^{(0)}) > J(\theta^{(1)}) > J(\theta^{(2)}) \dots > J(\theta^{(n)}) \quad \text{使得 } J(\theta^{(n)}) \text{ 越来越小}$$

思考: 对非线性系统, 是否要求太苛刻? 允许某些步的 $J(\theta)$ 增大吗?

3. 迭代算法的框架

$\theta^{(0)} \rightarrow$ 确定 V_i (迭代方向) $\rightarrow$ 确定 P_i (迭代步长) $\rightarrow \theta^{(i)} = \theta^{(i-1)} + P_i V_i$

向量 $\downarrow$ 向量 $\downarrow$ 向量 $\downarrow$ 标量

$J(\theta^{(i)}) < J(\theta^{(i-1)})$ 本次迭代是可接受的

问题: 如何确定 V_i 和 P_i ?

4. 迭代方向的确定

由于 R 是正定的, 不影响 V 的方向, 只改变步长 (大小), 故

$$\theta^{(i)} = \theta^{(i-1)} + P V = \theta^{(i-1)} + P G_{i-1} \quad \text{步长可通过 } P \text{ 来实现, 无需构造 } R \text{ 了, 且 } R \text{ 构造也不唯一}$$

目标是让 $J(\theta^{(i)})$ 减小, $J(\theta) \rightarrow J(V, P)$ $J(\theta)$ 和 V, P 有关

$$\frac{\partial J}{\partial P} = \left(\frac{\partial J}{\partial \theta} \right)^T \left(\frac{\partial \theta}{\partial P} \right) = \left(\frac{\partial J}{\partial \theta} \right)^T V \quad \text{思考: 想要看 } V \text{ 和 } J(\theta) \text{ 的关系, 为何不用 } \frac{\partial J}{\partial V}, \text{ 而用 } \frac{\partial J}{\partial P}?$$

$$\frac{\partial J}{\partial P} \bigg|_{P=0^+} = \left(\frac{\partial J}{\partial \theta} \right)^T \bigg|_{P=0^+} \cdot V \quad \text{若此处是 } \frac{\partial J}{\partial \theta}, \text{ 求偏导后, 函数中不含有 } V \text{ 了, 就没法考虑}$$

$$= \left(\frac{\partial J}{\partial \theta} \right)^T \bigg|_{\theta=\theta^{(i-1)}} \cdot V \quad V \text{ 对目标函数的影响了, 用 } \frac{\partial J}{\partial \theta}, \text{ 式子中含有 } P \text{ 和 } V, \text{ 然}$$

$$= G_{i-1}^T \cdot V \quad \text{后取 } P=0^+, \text{ 相当于 } P \text{ 对目标函数几乎无影响, 此时}$$

$$\text{梯度 } G_{i-1} = \frac{\partial J}{\partial \theta} \bigg|_{\theta=\theta^{(i-1)}} \quad \text{就可以考虑 } V \text{ 对目标函数的影响了。}$$

定理 6.1

一个方向 V 是可接受的, 当且仅当存在正定矩阵 $R > 0$, 使得 $V = -R G_{i-1}$

证: 充分性: 已知 $V = -R \cdot G_{i-1}$

$$\frac{\partial J}{\partial P} \bigg|_{P=0^+} = G_{i-1}^T V = -G_{i-1}^T R G_{i-1} < 0 \quad \text{可接受}$$

必要性: 已知 $G_{i-1}^T V < 0$

构造 $R = [I - G_{i-1} G_{i-1}^T / (G_{i-1}^T G_{i-1})] - V V^T / (V^T G_{i-1})$ 不唯一

$$V = -R G_{i-1} = [-G_{i-1} + G_{i-1} G_{i-1}^T G_{i-1} / (G_{i-1}^T G_{i-1})] + V V^T G_{i-1} / (V^T G_{i-1}) = V$$

假设 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]^T \neq 0$ 标量

$$\alpha^T R \alpha = \alpha^T \alpha - \alpha^T G_{i-1} G_{i-1}^T \alpha / (G_{i-1}^T G_{i-1}) - \alpha^T V V^T \alpha / (V^T G_{i-1})$$

$$= \sum \alpha_k^2 - (\sum \alpha_k g_k)^2 / (\sum g_k^2) - \alpha^T V V^T \alpha / (V^T G_{i-1})$$

$$\geq \sum \alpha_k^2 - (\sum \alpha_k^2 \sum g_k^2) / (\sum g_k^2) - \alpha^T V V^T \alpha / (V^T G_{i-1})$$

$$= -\alpha^T V V^T \alpha / (V^T G_{i-1})$$

≥ 0 非负

< 0

$V V^T$ 是对称矩阵

① 若 V 是 n 阶向量, 那么 $V V^T = 0$

当 $\alpha = \lambda G_{i-1}$ 时, 第一项等号成立, 此时

$$\forall \alpha \in \mathbb{R}^2, \det(\alpha \alpha^T) = 0$$

$$-\alpha^T V V^T \alpha / (V^T G_{i-1})$$

② 若 V 是多维向量, 当其中某个元素为 0 时,

$$= -\lambda G_{i-1}^T V V^T \lambda G_{i-1} / (V^T G_{i-1})$$

$V \cdot V^T$ 的行列式为 0.

$$= -\lambda^2 G_{i-1}^T V > 0$$

综上, $V \cdot V^T$ 为半正定矩阵

$$\theta^{(i+1)} = \theta^{(i)} - P \cdot R G_{i-1}$$

$-R G_{i-1}$ 相当于迭代方向, 则新方向

$$\text{则为 } \theta^{(i+1)} = \theta^{(i)} + P \cdot V \quad (\text{当 } R=0 \text{ 时})$$

§ 6.3 牛顿-拉夫森算法

考虑: $y = f(u, \theta)$

$$J(\theta) = \sum_{k=1}^N e^2(k)$$

迭代法: $-P \frac{\partial J}{\partial \theta} \bigg|_{\theta^{(i)}}$

$$\theta^{(i+1)} = \theta^{(i)} + \Delta \theta$$

思考: 参照最小二乘, 如何将目标函数 $J(\theta)$ 写成 θ 的二次型形式?

① 将 $y = f(u, \theta)$ 线性化 ② 直接将 $J(\theta)$ 化成二次型

将 $J(\theta)$ 在 $\theta = \theta^{(n)}$ 处二次化 (Taylor):

都是常数 $J(\theta) = J(\theta^{(n)}) + \left(\frac{\partial J}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)}) + \frac{1}{2} (\theta - \theta^{(n)})^T \frac{\partial^2 J}{\partial \theta^2} \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)}) + \lambda_0$ 不加余项
就忽略了 J 是标量, θ 是向量 雅克比矩阵 (是个向量) $\frac{\partial^2 J}{\partial \theta^2}$ 是个矩阵

注: 用一个单平衡点函数来近似一个多平衡点系统, 相当于用一个高斯分布来近似一个多峰系统, 是很不准的, 但计算方便。

怎么减少误差? 当非线性很强时, 步长取得小一点儿, 因为可线性化区间很小。

$$\frac{\partial J}{\partial \theta} = \left(\frac{\partial J}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} + \left(\frac{\partial^2 J}{\partial \theta^2}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)}) = 0$$

$$\theta^{(n+1)} = \theta^{(n)} - \left[\left(\frac{\partial^2 J}{\partial \theta^2}\right)^T \bigg|_{\theta=\theta^{(n)}}\right]^{-1} \left(\frac{\partial J}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}}$$

(误差问题:

梯度

$\left[\left(\frac{\partial^2 J}{\partial \theta^2}\right)^T \bigg|_{\theta=\theta^{(n)}}\right]^{-1}$ 逆不一定存在。一旦这两条件满足, 此方法的收敛速度很快。
 $\left[\left(\frac{\partial^2 J}{\partial \theta^2}\right)^T \bigg|_{\theta=\theta^{(n)}}\right]^{-1}$ 不一定正定 因为它是二阶算法, 迭代算法是一阶算法。

牛拉算法一步就可以使目标函数的二次型最小化, 但只是二次型, 原目标函数本身是否也最小化不得而知。

§6.4 麦夸特算法 (Levenberg - Marquardt)

$y = f(u, \theta)$ 结构 (f) 已知的非线性系统

$f(u, \theta)$ 在 $\theta = \theta^{(n)}$ 处线性化

$$f(u, \theta) = f(u, \theta^{(n)}) + \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)})$$

$$J(\theta) = \sum e^2(k) = \sum [y(k) - f(u(k), \theta)]^2 \quad G_i = \frac{\partial^2 J}{\partial \theta^2} \bigg|_{\theta=\theta^{(n)}} = -2 \sum \frac{\partial^2}{\partial \theta^2} \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta)]$$

$$= -2 \sum [y(k) - f(u(k), \theta^{(n)}) - \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)})]^2$$

$$\frac{\partial J}{\partial \theta} = 2 \sum - \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta^{(n)}) - \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)})]$$

$$= 2 \sum \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)}) - \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta^{(n)})] = 0$$

$$\Rightarrow \theta^{(n+1)} = \theta^{(n)} + \left[\sum \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}}\right]^{-1} \sum \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta^{(n)})] *$$

$$P_i \quad G_i = \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} \quad \text{半正定} \quad -\frac{1}{2} G_i$$

$$\text{则 } \theta^{(n+1)} = \theta^{(n)} - \frac{1}{2} F_i^{-1} \cdot G_i$$

$$\text{修正为: } \theta^{(n+1)} = \theta^{(n)} - \frac{1}{2} (F_i + \lambda I)^{-1} G_i \quad \lambda > 0$$

2017年12月14日

在(*)式中, $\sum \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} = P_i \geq 0$ 半正定

$$\text{则 } \theta^{(n+1)} = \theta^{(n)} + P_i^{-1} \sum \frac{\partial f}{\partial \theta} \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta^{(n)})]$$

$$G_i = \left(\frac{\partial^2 J}{\partial \theta^2}\right)^T \bigg|_{\theta=\theta^{(n)}} = -2 \sum \frac{\partial^2 f}{\partial \theta^2} \bigg|_{\theta=\theta^{(n)}} [y(k) - f(u(k), \theta^{(n)}) - \left(\frac{\partial f}{\partial \theta}\right)^T \bigg|_{\theta=\theta^{(n)}} (\theta - \theta^{(n)})]$$

$$\theta^{(n+1)} = \theta^{(n)} - \frac{1}{2} P_i^{-1} G_i \quad **$$

$$\text{麦夸特算法将 } \theta^{(n+1)} \text{ 修正为: } \theta^{(n+1)} = \theta^{(n)} - \frac{1}{2} (P_i + \lambda I)^{-1} G_i$$

(λ 充分大: 能收敛, 收敛太慢

λ 太大会破坏解的最优性, 因为与 ** 或相差太大, [最优解点有, 即 ** 或]

迭代方向是对的, 但迭代步长太大, 很容易一步就跳过最优解

λ 充分小: 不一定收敛

若将步长取小一点, 则目标函数原点在最优解附近变化就很慢, 步长取小了, 迭代次数会更多, 收敛速度慢。


问: 牛顿拉普森算法和普通迭代算法有自举吗?

(迭代算法通过多次迭代使得目标函数在局部达到最小;

牛拉则通过一次迭代就可以使目标函数的二次型达到最小。

Adaptive

麦夸特算法的核心是做自适应调整步长



关于选优算法的讨论

问题：① 局部最优 ② 初值敏感 ③ 收敛慢

① 所有的非线性问题，只要不是凸的，都存在局部最优问题

根本原因是非线性系统的多平衡点的存在

解决办法：允许系统以一定概率（小概率）向正梯度方向

或按照随机机制向负梯度方向（大概率）和正梯度方向（小概率）

② 按照随机机制多选几个初值，只选一个初值很可能陷入局部最优。

②. 自适应选择步长

• 动量法 $\theta^{(i+1)} = \theta^{(i)} - P \left(\frac{\partial J}{\partial \theta} \right) \bigg|_{\theta^{(i)}} = \theta^{(i)} + \Delta \theta^{(i+1)}$

$$\Delta \theta^{(i+1)} = -P \frac{\partial J}{\partial \theta} \bigg|_{\theta^{(i)}}$$

$$\Delta \theta^{(i+1)} = -P \frac{\partial J}{\partial \theta} \bigg|_{\theta^{(i)}} + \mu \Delta \theta^{(i)}$$

• 改变目标函数法 $J_1 = e^2 \quad J_2 = |e|$

当 $|\theta^{(i)} - \theta^{(i+1)}| > \varepsilon$ ，离平衡点很远时， $\left| \frac{\partial J_1}{\partial \theta} \right| > \left| \frac{\partial J_2}{\partial \theta} \right|$ ，取 J_1

当离平衡点很近时， $\left| \frac{\partial J_1}{\partial \theta} \right| < \left| \frac{\partial J_2}{\partial \theta} \right|$ ，选 J_2

$J = J_1 + J_2$ 离平衡点远， J_1 起主导作用

离平衡点近，让 J_2 起主导作用

• 随机梯度下降法 每次选择的目标函数样本是随机的，让随机选的目标函数样本减小的 $\Delta \theta$ 去修正。但问题是此时总的样本目标函数也可能增大。

第七章 结构未知的非线性系统辨识

§ 7.1 引言

$$y = f(u, \theta) \quad f \text{ 未知}$$

优化：① 解耦：将一个复杂系统分解成几个相互独立的子系统，对子系统分别做优化

然后再把它们协调考虑。

② 分层：底层处理基本问题，高层做优化控制。

GNBH 一种分组算法（基于数据的），类似于模块化；由苏联的依瓦连柯提出

$$y = f(x_1, x_2, \dots, x_p) \quad p \text{ 输入}$$

$$= b_0 + \sum_i a_i x_i + \sum_{i,j} a_{ij} x_i x_j + \sum_{i,j,k} a_{ijk} x_i x_j x_k + \dots$$

$u_i \quad u_{ij} \quad u_{ijk}$


只要阶次足够高,可以实现对任何复杂的非线性系统的逼近。

若 $p=10$, 阶次 3, 则由 a 组成的参数 θ 的维数: 285

$p=10$ 10 10万+

维数太高, 数据相关性太强, 病态不可避免

GMDH 核心: 解耦 和 部分实现



$$G(x_i, x_j) = a_0 + a_1 x_i + a_2 x_j + a_3 x_i^2 + a_4 x_j^2 + a_5 x_i x_j$$

$$\theta = [a_0, a_1, a_2, a_3, a_4, a_5]^T$$

$$\text{第一层: } y_{1,1} = G(x_1, x_2)$$

$$y_{1,2} = G(x_2, x_3)$$

第一层的输出是原始输入的二阶

$$y_{1,p} = G(x_{p-1}, x_p)$$

挑选出的 $y_{1,i}$ 送下一层

$$\text{第二层: } y_{2,1} = G(y_{1,1}, y_{1,2})$$

第二层的输入是第一层的输出

第二层的输出是第一层输出的二阶

$$y_{2,p} = G(y_{1,p-1}, y_{1,p})$$

第二层的输出是原始输入的四阶

$$\text{第 } n \text{ 层: } y_n = G(y_{n-1,1}, y_{n-1,2})$$

第三层的输出是原始输入的二阶

边界条件越苛刻, 阶次越高

对非线性系统, 约束条件多的地方选择插值要多, 约束条件少的地方选择插值要少

建模步骤: ① 数据分组 { 拟合组 D_f (多) 对应 训练集 (神经网络) } 独立, 同分布

检验组 D_v (较少) 对应 测试集 (神经网络)

评价组 D_e (少): 对最后一层输出作检验

② 用 D_f 拟合当前层的部分实现 (用最小二乘 L.S)

③ 用 D_v 检验每个部分实现, 检验结果好, 保留

检验结果不好, 剪切掉

④ 重复②③, 直到终止条件

预测控制和卡尔曼滤波都是基于过程控制的系统模型, 都可以进行多步预测。

启发式方法, 不严谨, 漏洞多

对外部条件要求不苛刻, 可发挥空间大。

$$\text{另: } G(x_i, x_j) = \begin{cases} a_0 + a_1 x_i + a_2 x_j + a_3 x_i x_j \\ a_0 + a_1 x_i + a_2 x_j + a_3 x_i^2 + a_4 x_j^2 + a_5 x_i x_j \\ b_0 + b_1 x_i + b_2 x_j + b_3 x_i x_j \\ \exp(a_0 + a_1 x_i + a_2 x_j + \dots) \end{cases}$$

(关于部分实现)


$$a_0 + a_1 x_i + a_2 x_j$$

$$a_0 + a_1 x_i + a_2 x_j + a_3 x_i^2 + a_4 x_j^2 + a_5 x_i x_j$$

$$b_0 + b_1 x_i + b_2 x_j + b_3 x_i x_j$$

$$\exp(a_0 + a_1 x_i + a_2 x_j + \dots)$$

关于分组: PESS



将 D_1 作为检验组, 剩下的 $D_2, \dots, D_n$ 作拟合组

得到拟合函数 $\hat{G}_1$, 然后将检验组 x_1 代入 $\hat{G}_1$

就可以得到第一组估计值 $\hat{y}_1$

同理, 将 D_2 作为检验组, 剩下的 $D_1, D_3, \dots, D_n$ 作

拟合组得到 $\hat{G}_2$, 将 x_2 代入 $\hat{G}_2$ 即可得 $\hat{y}_2$

同理得到 $\hat{y}_2, \dots, \hat{y}_n$

$$PESS = \sum_{k=1}^n \|y(k) - \hat{y}(k)\|^2$$

12月21日

GMDH方法的优缺点总结:

优点: ① 层次化结构, 可以降低运算复杂度

② 层次化结构, 多为串行的, 易于实现, 比较简便

③ 层次化结构使得对全部的实现估计变为部分的实现估计, 系统的病态减轻

④ 当数据量较少时, PESS 依然能够利用系统的信息较准确地建立模型

→ PESS 本身的特点

* GMDH 的层次化结构配以 PESS 的特点, 降低了对数据量要求的要求

⑤ 系统的真实面目存在且存在于数据中

因为 GMDH 利用了最朴素的多项式拟合, 没有任何其他的假设, 能决定模型的就只有数据

⑥ GMDH 是一种启发式算法, 泛化性强, 适用性广, 实现起来比较灵活, 无模型限制

缺点: ① GMDH 的病态减轻, 但并非没有病态

当阶次比较高时, 这一层的部分输出都比较准确, 都很相似, 把这层输出作为下一层的输入, 下一层的拟合就会不准确

出现这种情况时, 下一层选用不同的部分实现的了的形式

② GMDH 是一种启发式算法, 无模型限制, 实现起来比较随意, 如阶次多高算高

③ GMDH 对参数、初值和分辨率敏感, 无法确定哪个模型好

④ 对多项式拟合采用层次化结构, 主效应很大

固化了多项式结构, 肯定会导致信息丢失

GMDH 对刻意复杂系统较为适合, 对简单系统不太适合

如: 本是一个简单的模型, 却要采用 32 阶甚至 32 阶多项式去拟合, 复杂

例 7.1 股价预测

 H_n — 第 n 个交易日的最高价 L_n — 第 n 个交易日的最低价 C_n — 第 n 个交易日的收盘价 O_n — 第 n 个交易日的开盘价 V_n — 第 n 个交易日的交易量

$$OBV_n = \frac{C_n - L_n - (H_n - C_n)}{H_n - L_n} \cdot V_n$$

能量潮: 刻画系统的能量

能量越高, 运动变化越剧烈

预测未来某天的收盘价 C_n

$$\textcircled{1} \bar{H}_n = \frac{1}{n} \sum_{k=1}^n H_k$$

① 滤波 (方法有: 取平均值...) 只要滤波, 优先考虑卡尔曼滤波

$$\bar{H}_n = \frac{1}{n} \sum_{k=1}^n H_k$$

$$\bar{L}_n = \frac{1}{n} \sum_{k=1}^n L_k$$

$$\bar{C}_n = \frac{1}{n} \sum_{k=1}^n C_k$$

$$\bar{O}_n = \frac{1}{n} \sum_{k=1}^n O_k$$

$$\bar{V}_n = \frac{1}{n} \sum_{k=1}^n V_k$$

$$\bar{OBV}_n = \frac{1}{n} \sum_{k=1}^n OBV_k$$

② 输入/输出数据

以 2000.6.15 ~ 2001.11.8 共 335 个连续交易日

$$x_1 = \bar{C}_n, x_2 = \bar{O}_n, x_3 = \bar{H}_n, x_4 = \bar{L}_n, x_5 = \bar{V}_n, x_6 = \bar{OBV}_n$$

PESS 选择中间变量

$$y_2 = 5.41 y_{2,1} + 141.50 y_{2,2} + 200.3$$

$$\text{where } \begin{cases} y_{2,1} = y_{1,1} & \text{关于 } x \text{ 的二阶多项式} \\ y_{2,2} = 0.10 y_{1,2} - 0.12 y_{1,1} y_{1,2} + 0.03 y_{1,1}^2 + 0.03 y_{1,2}^2 & \text{4 阶} \end{cases}$$

$$y_{1,1} = 256 \times 10^{-7} x_6 - 0.01$$

$$y_{1,2} = -0.16 x_1 + 0.17 x_2 - 0.104 \times 10^{-4} x_1 x_2 + 1.03 \times 10^{-4} x_1^2 - 16.92 \quad \text{二阶}$$

 x_3, x_4, x_5 等上面的模型中没有出现, 说明它们对股票影响不大

第八章 神经网络模型及其辨识

§8.1 引言

1943 提出 M-P 模型 基于单元的

50年代 提出感知机

50年代末60年代初 神经网络高潮期

1969 进入低潮期

1982年 Hopfield 提出 J hopfield 网络, 奠定了神经网络的理论基础。

Hopfield 网络的两个功能: 优化计算

联想记忆

人工神经网络 ANN (Artificial Neural Networks)


§8.2 神经元与人工神经元

 $u \rightarrow \boxed{NN} \rightarrow y$ 建模

MP模型: 描述单个神经元的输入/输出关系

 $y \rightarrow \boxed{NN} \rightarrow u$ 控制

一定有多解



(t+1)时刻第i个神经元的状态

由y到u, 一般是不可逆的

说明: 不可逆的问题神经网络有解。

$$S_i(t+1) = f\left(\sum_j W_{ij} S_j(t) - \mu_i\right)$$

$$f(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases} \quad \begin{cases} \mu_i - \text{阈值} \\ W_{ij} - \text{权} \\ f(\cdot) - \text{一种非线性关系} \end{cases}$$

$$f(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases} \quad (\text{激活})$$

神经网络对 $f(\cdot)$ 形式和 μ 值不敏感

① 0-1


② 线性 $f(x) = kx$ $x = \sum_j W_{ij} S_j(t) - \mu_i$

③ $f(x) = \frac{1}{1+e^{-kx}}$ ✓

④ $f(x) = \frac{1-e^{-kx}}{1+e^{-kx}}$ ✓

⑤ $f(x) = e^{-\frac{x^2}{2\sigma^2}}$

⑥ $f(x) = \frac{1}{1+|x|}$



前馈神经网络

带输出反馈的前馈神经网络

层内互连的前馈神经网络

(同一层神经元有连接)

循环

分类

§8.4 前馈神经网络模型


当网络的规模充分大, 就可以实现对任意非线性系统的任意精度的逼近。

苏联XX证明: 隐含层节点数足够多的三层前馈神经网络可以实现对任意非线性系统的任意精度的逼近。

网络规模充分大: 层数足够多

每一层节点数足够多

神经网络的学习/训练: $f(\cdot)$ 固化成=值, S形或双曲正切函数。 μ_i 对输出关系影响不大, 通常取 $\mu_i = 0$ W_{ij} : 不同的系统在神经网络中的不同体现在权 W_{ij} 上。



Autoencoder

令输出和输入相等，训练隐层

↳ 输入到隐层的映射与隐层到输出的映射互逆。


应用：① 特征提取

② 压缩感知，降维

12月28日

§ 9.4 前馈神经网络模型及其辨识

1. 网络结构



网络的输入输出关系：

隐层结点 h_j 的输入： $I_{hj} = \sum_k w_{jk} x_k$

隐层结点 h_j 的输出： $O_{hj} = f(I_{hj})$

输出层结点 y_i 的输入： $I_{yi} = \sum_j w_{ij} O_{hj}$

输出层结点 y_i 的输出： $O_{yi} = f(I_{yi})$

↳ 称为 y_i

随着层数的增高，输出的非线性越强。

2. 权重的辨识

X, Y are given 给定： $x_1, x_2, \dots, x_p$

待求 $W = [w_{ij}, w_{jk}]$

构造目标函数 $J(W) = \frac{1}{2} \sum_i [Y_i(t) - \hat{Y}_i(t)]^T [Y_i(t) - \hat{Y}_i(t)]$

$$= \frac{1}{2} \sum_i [y_i(t) - O_{yi}(t)]^2$$

$$W^* = \arg \min J(W)$$

是一个典型的非线性最小二乘问题，可以用麦夸特、牛顿、迭代等方法解

$$w_{ij}(t+1) = w_{ij}(t) - \eta \frac{\partial J}{\partial w_{ij}}$$

当 i, j 给定： $\frac{\partial J}{\partial w_{ij}} = \sum_k [y_i(t) - O_{yi}(t)] [-f'(I_{yi})] \cdot O_{hj}$ 可求

求导时，只有与给定 i, j 相同的那一项才有，其他都设了。

$$w_{jk}(t+1) = w_{jk}(t) - \eta \frac{\partial J}{\partial w_{jk}}$$

当 j, k 给定： $\frac{\partial J}{\partial w_{jk}} = \frac{\partial J}{\partial w_{ij}} \cdot \frac{\partial w_{ij}}{\partial w_{jk}}$

$$= \sum_i [y_i(t) - O_{yi}(t)] [-f'(I_{yi})] w_{ij} f'(I_{hj}) x_k$$

此算法即为传播算法 (BP)

修正时，先修正输出层，接着修正高隐层，低隐层，最后是输入层。

计算时，先计算 $\frac{\partial J}{\partial w_{ij}}$ ，再算 $\frac{\partial J}{\partial w_{jk}}$

神经网络训练流程:

① 确定网络结构. 确定隐含层层数和结点数. 上节课说过, 隐含层一层就够, 关键是选多少结点. 有几个经验性的准则:

$$n_H \geq \begin{cases} \sqrt{n_I + n_O} + \lambda & \lambda \in [1, 10] \\ 2(n_I + n_O) + 1 & n_I: \text{输入层结点数} \\ \log_2(n_I + n_O) & n_O: \text{输出层结点数} \end{cases}$$

② 确定 w .

③ 迭代算法优化

可能会将目标函数修正为: $\frac{1}{2} [J^T J] + \|w\|_2$

增加它的泛化能力 (提高它的普适性, 变成一个较为通用的)

第九章 遗传算法及其在辨识中的应用

§ 9.1 引言

除了遗传算法, 还有几种进化计算的算法.

GA (遗传算法), PSO, SA, Ant (蚁群算法), Bee (蜂群算法), 细菌算法.

免疫算法

遗传算法是 1975 年 J. H. Holland 教授提出的.

Generic Algorithm 具有群体性

§ 9.2 GA 的基本思路

1. 一般的优化: $x(0) \xrightarrow{\Delta x} x(1) \xrightarrow{\Delta x} x(2) \dots \rightarrow x^*$

群体 $P_0 \rightarrow P_1$

↑
体
↓
 $\begin{cases} x_1(0) \\ x_2(0) \\ \vdots \\ x_N(0) \end{cases}$

① 遗传算法具有全局优化的能力, 但也有局部最优问题 (若参数调不好, 初值设置不好...)

② 是以量取胜, 鲁棒性很强

2. 5 自然选择

自然遗传

3. GA 的 5 要素: ① 问题可行解的遗传表示

② 种群初始化

③ 适应度函数

④ 遗传操作: 选择, 交叉, 变异

⑤ 基本参数

§ 9.3 GA 在辨识中的具体实现

$$y = f(u, \theta)$$

$$J(\theta) = \frac{1}{2} \sum_{k=1}^N [y(k) - f(u(k), \theta)]^T [y(k) - f(u(k), \theta)]$$

$$\theta^* = \arg \min J(\theta)$$

1. 编码

$$\text{假设 } \theta = [\theta_1, \theta_2, \dots, \theta_n]^T \in \mathbb{R}^n$$

其中 $\theta_i \in [l_i, v_i]$ 解的精度 10^{-6}

GA 采用 0-1 串表示问题的可行解

$$\theta_i \times 10^6 \in [l_i \times 10^6, v_i \times 10^6]$$

用 m_i 位 0-1 串表示 θ_i , 其中 m_i 满足 $2^{m_i-1} < (v_i - l_i) \times 10^6 < 2^{m_i}$


用 $m = \sum m_i$ 位 0-1 串表示 θ

2. 种群初始化

随机初始化 N 个 m 位 0-1 串 θ_i ($i = 1, \dots, N$)

3. 适应度函数 $f(\theta) = \frac{1}{1+j(\theta)}$

4. 选择 轮盘赌



每个个体被选中的概率:

$$p_i = \frac{f(\theta_i)}{\sum_{j=1}^n f(\theta_j)} \propto f(\theta_i)$$

适应度函数

5. 交叉 (crossover) P_c

$$P_c = 0.5 \sim 0.9$$

$\theta_1: 01|00|00|1100 \quad Y_1 < P_c \quad \checkmark \quad \text{参与交叉}$

$\theta_2: 10|11|11|1111 \quad Y_2 < P_c \quad \checkmark$

$\theta_3: 01|10|10|0001 \quad Y_3 > P_c \quad \times \quad \text{不参与交叉}$

$\theta_4: 10|11|11|1111 \quad Y_4 < P_c \quad \checkmark$

参与交叉的两两配对 (随机)

6. 变异 (Mutation)

变异概率: $P_m = 0.001 \sim 0.01$

01100111

每个 θ 的每一位都产生一个随机数 Y_i

$Y_1 > P_m \quad Y_6 < P_m$

产生变异 (0 变成 1, 1 变成 0)

7. 终止条件, 例 13.1

8. GA 的改进: 精英保留 (能保证算法的收敛性, 将精英个体一定遗传到下一代)

自适应变异: 在交叉前度量交叉双方的差异。若差异大, 则交叉后变化的可能性

大, 用小的变异概率; 差异小, 则用大的变异概率。

多种群交叉

遗传算法考试: 给出一个函数, 求编码适应度函数 (带自己答)

大脑皮层区域间联系是它们之间连接的联系 大脑皮层的连接方式由基因决定

大脑皮层的算法独立于其它特殊功能和感知, 大脑用同样的方式去看, 去“听”, 大脑皮层的作用具有普遍性, 适用于任何一种感觉或运动系统

通用算法 神经网络

$$I = x + y + w$$

$$Z = [x \ y] \cdot \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$$

$$x \cdot w_1$$

$$\begin{bmatrix} 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

$$x \cdot w_2$$

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$x \cdot w_1$$

$$p = \frac{1}{1 + e^{-z}}$$

$$z = w_1 \cdot x + w_2 \cdot y$$

$$z = w_1 \cdot x + w_2 \cdot y$$

$$V = W \cdot R$$

$$V = \frac{z}{L}$$

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$x \cdot w_1$$

$$x \cdot w_2$$

$$x \cdot w_1$$

$$x \cdot w_1$$

$$x \cdot w_1$$

$$L_1 + d \cdot s \cdot c$$